Multivariate Verfahren

Diskriminanzanalyse

Annika Hoyer

Sommersemester 2021

Diskriminanzanalyse - Inhalt

Ausgangssituation

Diskriminanzanalyse

Diskriminanzanalyse bei normalverteilten Grundgesamtheiten

Diskriminanzanalyse nach Fisher

k-nächste Nachbarn

Logistische Diskriminanzanalyse

Ausgangssituation

Ausgangssituation

- ▶ Grundgesamtheit zerfällt in $g \ge 2$ disjunkte Klassen mit Indikator $Y \in \{1, ..., g\}$
- Beobachtung von Merkmalsvektoren x₁,...,x_n
- ► Aber: Klassenzugehörigkeit *Y*₁,..., *Y*_n unbekannt

Problemstellung

Die Objekte a_1, \ldots, a_n sollen mithilfe der an ihnen beobachteten Merkmalsvektoren in eindeutiger Weise jeweils genau einer Klasse zugeordnet werden.

Beispiele

- Unterscheidung von Kreditnehmern (vertrauenswürdig / nicht vertrauenswürdig)
- Klassifizierung von Krankheiten (Bronchitis / Lungenentzündung)
- Bestimmung des Krankheitsstatus (krank / gesund)
- Identifizierung von Drogenkonsumenten (User / Non-User)
- Mustererkennung in Texten (Buchstaben)

Merkmale der Diskriminanzanalyse

- Klassen, in die Objekte eingeteilt werden sollen, sind vorab bekannt
- Diskriminanzanalyse ist Verfahren des "supervised learning"
- Synonyme: "Klassifikation" und "Pattern Recognition"
- Grundlage: Fehlerraten bzw.
 Fehlklassifikationswahrscheinlichkeiten
- Auswahl der Merkmale, die für die Klassifikation herangezogen werden, ist von zentraler Bedeutung

Datengrundlage

Der Merkmalsvektor **x** und die Klasse Y sind charakterisiert durch:

a priori-Wahrscheinlichkeiten:

$$p(r) = P(Y = r), r = 1, ..., g$$

a posteriori-Wahrscheinlichkeiten:

$$P(r|\mathbf{x}) = P(Y = r|\mathbf{x}), r = 1, \dots, g$$

▶ die Dichte von **x** gegeben der Klasse:

$$f(\mathbf{x}|Y=1),\ldots,f(\mathbf{x}|Y=g)$$

die Mischverteilung in der Gesamtpopulation:

$$f(\mathbf{x}) = \sum_{i=1}^{g} f(\mathbf{x}|j) \rho(j)$$

Diskriminanzanalyse

- Test zur Mittelstufenalgebra (26 Fragen) im Wintersemester 1988/89 bei Studienanfängern der Wirtschaftswissenschaften an der FU Berlin
- Variablen:
 - Geschlecht: w/m (1/0)
 - Besuch Leistungskurs Mathe: j/n (1/0)
 - Abitur im Jahr 1988: j/n (1/0)
 - Abinote Mathematik
 - Anzahl der im Test richtig gelösten Aufgaben
 - ► Gruppe 1: mindestens 14 Punkte erreicht → Test bestanden
 - ▶ Gruppe 2: weniger als 14 Punkte → Test nicht bestanden

Ergebnisse der Studienanfänger bei dem Mathetest

Geschlecht	MatheLK	MatheNote	Abitur88	Gruppe
0	0	3	0	2
0	0	4	0	2
0	0	4	0	2
0	0	4	0	2
1	0	3	0	2

- 20 Studierende: 9 in Gruppe 1, 11 in Gruppe 2
- ➤ Ziel: Ordne Studierenden der Gruppe zu, zu der er gehört, ohne zu wissen, um welche Gruppe es sich handelt
- → basierend auf Merkmalen

Kontingenztabelle der Merkmale Geschlecht und Gruppe

	Gruppe	1	2
Geschlecht			
0		4	6
1		5	5

Verteilung des Merkmals Geschlecht in den Gruppen

	Gruppe	1	2
Geschlecht			
0		0.44	0.55
1		0.56	0.45

- ► Liegt Gruppe 1 vor, beträgt Wahrscheinlichkeit, eine weibliche Person auszuwählen 5/9 = 0.56
- ► Liegt Gruppe 2 vor, beträgt Wahrscheinlichkeit, eine weibliche Person auszuwählen 5/11 = 0.45
- ightarrow Wahrscheinlicher, aus Gruppe 1 eine weibliche Person auszuwählen, als aus Gruppe 2
- → Entscheiden uns für Gruppe, bei der Merkmalsausprägung "weiblich" wahrscheinlicher ist

Maximum-Likelihood-Zuordnung

- Zuordnung beruht auf Likelihood-Prinzip
- Sei X das Merkmal "Geschlecht"

$$f_i(x) = P(X = x \mid \text{Person kommt aus Gruppe } i)$$

► Es gilt:

$$f_1(0) = \frac{4}{9} = 0.44, \quad f_1(1) = \frac{7}{9} = 0.56$$

$$f_2(0) = \frac{6}{11} = 0.55$$
 $f_2(1) = \frac{5}{11} = 0.45$

Maximum-Likelihood-Zuordnung für 2 Gruppen

Definition: Maximum-Likelihood-Zuordnung

Ein Objekt mit Merkmalsausprägung x wird nach der Maximum-Likelihood-Zuordnung der Gruppe 1 zugeordnet, wenn gilt

$$\frac{f_1(x)}{f_2(x)} > 1.$$

Es wird der Gruppe 2 zugeordnet, wenn gilt

$$\frac{f_1(x)}{f_2(x)}<1.$$

Gilt

$$\frac{f_1(x)}{f_2(x)}=1,$$

so kann man es willkürlich einer der beiden Gruppen zuordnen.

Maximum-Likelihood-Zuordnung für *r*-Klassen

Definition: Maximum-Likelihood-Zuordnung

Ordne das Objekt mit Merkmalsvektor **x** derjenigen Klasse zu, für welche die Dichte maximal ist, d.h.:

$$\delta_{\mathsf{ML}}(\mathbf{x}) = r \Leftrightarrow f(\mathbf{x}|r) = \max_{j} f(\mathbf{x}|j)$$

- Betrachten Merkmale Geschlecht und MatheLK gleichzeitig
- Merkmalspaar (x₁, x₂) mit x₁ = Geschlecht und x₂ = MatheLK

	Gruppe	1	2
(x_1, x_2)			
(0,0)		0.00	0.45
(0,1)		0.44	0.09
(1,0)		0.11	0.27
(1,1)		0.44	0.18

 \rightarrow Ordne Studierenden Gruppe 1 zu, wenn er die Merkmalsausprägungen (0,1) oder (1,1) besitzt

Bayes-Zuordnung

- Maximum-Likelihood-Zuordnung berücksichtigt nicht, dass Populationen unterschiedlich groß sein können
- ► a priori-Wahrscheinlichkeiten:

$$p(r) = P(Y = r), r = 1, ..., g$$

 Multipliziere Likelihood-Funktionen mit priori-Wahrscheinlichkeiten, um Populationsgröße zu berücksichtigen

Bayes-Zuordnung, 2-Gruppen-Fall

Definition: Bayes-Zuordnung

Eine Objekt mit Merkmalsausprägung **x** wird nach der Bayes-Zuordnung der Gruppe 1 zugeordnet, wenn gilt

$$p(1)f_1(\mathbf{x}) > p(2)f_2(\mathbf{x}).$$

Es wird Gruppe 2 zugeordnet, wenn gilt

$$p(1)f_1(\mathbf{x}) < p(2)f_2(\mathbf{x}).$$

Gilt

$$p(1)f_1(\mathbf{x}) = p(2)f_2(\mathbf{x}).$$

so kann man es willkürlich einer der beiden Gruppen zuordnen.

Gruppe	1	2
	4	6
	5	5
	Спирре	4

• Es gilt: p(1) = 0.45 und p(2) = 0.55

$$p(1)f_1(0) = 0.45 \cdot \frac{4}{9} = 0.2$$

$$p(2)f_2(0) = 0.55 \cdot \frac{6}{11} = 0.3$$

$$p(1)f_1(1) = 0.45 \cdot \frac{5}{9} = 0.25$$

$$p(2)f_2(1) = 0.55 \cdot \frac{5}{11} = 0.25$$

- ▶ Person wird Gruppe 2 zugeordnet, wenn sie männlich ist
- ▶ Weibliche Person wird willkürlich einer Gruppe zugeordnet

Bayes-Zuordnung

- ▶ a posteriori-Wahrscheinlichkeiten: $P(Y = 1 \mid \mathbf{x}), P(Y = 0 \mid \mathbf{x})$
- Satz von Bayes:

$$P(Y = 1 \mid \mathbf{x}) = \frac{p(1)f_1(\mathbf{x})}{f(\mathbf{x})}$$

$$P(Y = 0 \mid \mathbf{x}) = \frac{p(2)f_2(\mathbf{x})}{f(\mathbf{x})}$$

mit

$$f(\mathbf{x}) = p(1)f_1(\mathbf{x}) + p(2)f_2(\mathbf{x}).$$

Es gilt:

$$\rho(1)f_1(\mathbf{x}) = P(Y = 1 \mid \mathbf{x})f(\mathbf{x})
\rho(2)f_2(\mathbf{x}) = P(Y = 0 \mid \mathbf{x})f(\mathbf{x})$$

ightarrow Ein Objekt mit Merkmalsausprägung ${\bf x}$ wird nach der Bayes-Zuordnung der Gruppe 1 zugeordnet, wenn gilt

$$P(Y = 1 \mid \mathbf{x}) > P(Y = 0 \mid \mathbf{x})$$

	Gruppe	1	2
Geschlecht			
0		4	6
1		5	5

$$P(Y = 0 \mid 0) = 0.6$$

 $P(Y = 1 \mid 0) = 0.4$
 $P(Y = 0 \mid 1) = 0.5$
 $P(Y = 1 \mid 1) = 0.5$

Bayes-Zuordnung

Definition: Bayes-Zuordnung

Ordne das Objekt mit Merkmalsvektor **x** derjenigen Klasse zu, für welche die a posteriori-Wahrscheinlichkeit maximal ist, d.h.:

$$\delta(\mathbf{x}) = r \Leftrightarrow P(r|\mathbf{x}) = \max_{j} P(j|\mathbf{x}).$$

Wie erhält man die Zuordnung?

- ▶ $P(Y = r | \mathbf{x})$ bekannt $\sqrt{}$
- ▶ $f(\mathbf{x}|Y = r)$ bekannt → Berechnung über den Satz von Bayes

$$P(r|\mathbf{x}) = \frac{f(\mathbf{x} \mid r)p(r)}{\sum_{j=1}^{g} f(\mathbf{x} \mid j)p(j)}$$

Zuordnung		wahre Gruppe		
	Y = 1	Y = 2		Y = g
Y = 1	✓	$P(\delta(\mathbf{x}) = 1 \mid Y = 2)$		$P(\delta(\mathbf{x}) = 1 \mid Y = g)$
Y = 2	$P(\delta(\mathbf{x}) = 2 \mid Y = 1)$	✓		$P(\delta(\mathbf{x}) = 2 \mid Y = g)$
:	:	:	٠.	:
Y = g	$P(\delta(\mathbf{x}) = g \mid Y = 1)$	$P(\delta(\mathbf{x}) = g \mid Y = 2)$		\checkmark

- ▶ Verwechslungswahrscheinlichkeiten: Wahrscheinlichkeit, ein Objekt der Klasse s zuzuordnen, obwohl es aus Klasse r stammt ($s \neq r$)
- Gesamtfehlerrate: Wahrscheinlichkeit mit einer Entscheidungsregel eine falsche Zuordnung zu erhalten

Sei δ eine bestimmte, feste Zuordnungsregel und (\mathbf{x}, Y) ein Zufallsvektor.

Gesamtfehlerrate

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y), \quad \delta(\mathbf{x}) \in \{1, \dots, g\}$$

Fehlklassifikation, gegeben x

$$\varepsilon(\mathbf{x}) = P(\delta(\mathbf{x}) \neq Y|\mathbf{x})$$
$$= 1 - P(\delta(\mathbf{x}) = Y|\mathbf{x})$$

Sei δ eine bestimmte, feste Zuordnungsregel und (\mathbf{x}, Y) ein Zufallsvektor.

Verwechslungswahrscheinlichkeit

$$\varepsilon_{rs} = P(\delta(\mathbf{x}) = s|Y = r) = \int_{\mathbf{x}:\delta(\mathbf{x})=s} f(\mathbf{x}|r)dx$$

Fehlklassifikation, gegeben Klasse r

$$\varepsilon_r = P(\delta(\mathbf{x}) \neq r | Y = r) = \sum_{r \neq s} \varepsilon_{rs}$$

Es gelten folgende Zusammenhänge:

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \sum_{r=1}^{g} P(\delta(\mathbf{x}) \neq r | Y = r) p(r)$$
$$= \sum_{r=1}^{g} \varepsilon_r p(r) = \sum_{r=1}^{g} \sum_{s \neq r} \varepsilon_{rs} p(r)$$

und

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \int P(\delta(\mathbf{x}) \neq Y | \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$
$$= \int \varepsilon(\mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

	Gruppe	1	2
Geschlecht			
0		4	6
1		5	5

- Ordnen Person Gruppe 2 zu, wenn sie m\u00e4nnlich ist
- Verwechslungswahrscheinlichkeiten:
 - 1. Ordne Mann aus Gruppe 1 fälschlicherweise Gruppe 2 zu:

$$\varepsilon_{12} = P(\delta(\mathbf{x}) = 2|Y = 1) = \frac{4}{9} = 0.44$$

Ordne Frau aus Gruppe 2 fälschlicherweise Gruppe 1 zu:

$$\varepsilon_{21} = P(\delta(\mathbf{x}) = 1 | Y = 2) = \frac{5}{11} = 0.45$$

Gesamtfehlerrate:

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \sum_{r=1}^{2} P(\delta(\mathbf{x}) \neq r | Y = r) p(r)$$

= 0.44 \cdot 0.45 + 0.45 \cdot 0.55 = 0.4455

Optimalität der Bayes-Zuordnung

Optimalität Bayes-Zuordnung

Unter allen Entscheidungsregeln besitzt die Bayes-Zuordnung für alle \mathbf{x} die kleinste bedingte Fehlerrate, wenn \mathbf{x} beobachtet wird, und damit auch die kleinste Gesamtfehlerrate. Sie ist im Sinne der Gesamtfehlerrate also optimal.

Es gilt

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \int \varepsilon(\mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

- $\rightarrow \varepsilon$ minimal, falls $\varepsilon(\mathbf{x})$ für alle \mathbf{x} minimal
- \rightarrow minimiere $\varepsilon(\mathbf{x}) = 1 P(\delta(\mathbf{x})|\mathbf{x})$

Diskriminanzfunktion

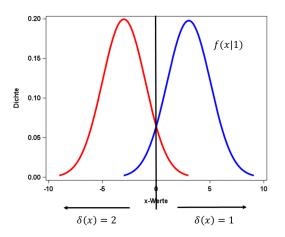
- $ightharpoonup d_r(\mathbf{x}) = P(r|\mathbf{x})$ heißt Diskriminanzfunktion
- ► Formulierung der Bayes-Zuordnung:

$$\delta(\mathbf{x}) = r \Leftrightarrow d_r(\mathbf{x}) = \max_j d_j(\mathbf{x}).$$

- Äquivalent:
 - $d_r(\mathbf{x}) = f(\mathbf{x}|r)p(r)$
 - $d_r(\mathbf{x}) = \log(f(\mathbf{x}|r)) + \log(p(r))$

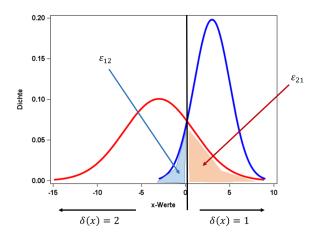
Veranschaulichung der Bayes-Zuordnung

Betrachte zwei Klassen, wobei gilt: p(1) = p(2)



Veranschaulichung der Bayes-Zuordnung

Betrachte zwei Klassen, wobei gilt: p(1) > p(2)



Kostenfunktion:

$$c(r,\hat{r})=c_{r\hat{r}}$$

- Annahmen:
 - $c_{r\hat{r}} \geq 0$
 - $c_{rr} = 0$

- \triangleright δ : bestimmte, feste Zuordnungsregel
- ▶ (x, Y): neue Beobachtung
- $\rightarrow c_{Y,\delta(\mathbf{x})}$ ist Zufallsvariable
 - ▶ Bestimmung von δ über zu erwartenden Schaden $R := \mathbb{E}_{Y,\mathbf{x}}(c_{Y,\delta(\mathbf{x})})$

Bedingtes Risiko, gegeben x

$$r(\mathbf{x}) = \sum_{r=1}^{g} c_{r,\delta(\mathbf{x})} P(r|\mathbf{x}) = \mathbb{E}_{Y|\mathbf{x}}(c_{Y,\delta(\mathbf{x})})$$

→ Zu erwartender Schaden bei gegebenem x

Als Gesamt-Risiko ergibt sich:

$$R = \mathbb{E}_{Y,\mathbf{x}}(c_{Y,\delta(\mathbf{x})}) = \mathbb{E}_{\mathbf{x}} \left(\mathbb{E}_{Y|\mathbf{x}}(c_{Y,\delta(\mathbf{x})}) \right)$$

$$= \mathbb{E}_{\mathbf{x}} \left(\sum_{r=1}^{g} c_{r,\delta(\mathbf{x})} P(r|\mathbf{x}) \right)$$

$$= \int \sum_{r=1}^{g} c_{r,\delta(\mathbf{x})} P(r|\mathbf{x}) f(\mathbf{x}) d\mathbf{x} = \int r(\mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

 \rightarrow Die Minimierung von $r(\mathbf{x})$ für jedes \mathbf{x} ergibt eine Minimierung des Gesamt-Risikos R.

Ordne Objekt mit Merkmalsvektor x derjenigen Klasse zu, für welche der zu erwartende Schaden minimal ist, d.h.:

$$\delta_K(\mathbf{x}) = r \iff \sum_{k=1}^g c_{kr} P(k|\mathbf{x}) = \min_j \sum_{k=1}^g c_{kj} P(k|\mathbf{x})$$

Mit Diskriminanzfunktionen

$$d_r(\mathbf{x}) = -\sum_{k=1}^g c_{kr} P(k|\mathbf{x}),$$

erhält man

$$\delta_K(\mathbf{x}) = r \Leftrightarrow d_r(\mathbf{x}) = \max_i d_j(\mathbf{x})$$

Kostenoptimale Bayes-Zuordnung für 2 Gruppen

Kostenoptimale Bayes-Zuordnung, 2 Gruppen

Seien c_{12} die Kosten, die entstehen, wenn man ein Objekt, das in Gruppe 1 gehört, irrtümlich Gruppe 2 zuordnet, und c_{21} die Kosten, die entstehen, wenn man ein Objekt, das in Gruppe 2 gehört, irrtümlich Gruppe 1 zuordnet. Ein Objekt mit Merkmalsvektor \mathbf{x} wird nach der kostenoptimalen Entscheidungsregel der Gruppe 1 zugeordnet, wenn gilt

$$c_{21}p(2)f_2(\mathbf{x}) < c_{12}p(1)f_1(\mathbf{x}).$$

Es wird Gruppe 2 zugeordnet, wenn gilt

$$c_{21}p(2)f_2(\mathbf{x}) > c_{12}p(1)f_1(\mathbf{x}).$$

Gilt

$$c_{21}p(2)f_2(\mathbf{x}) = c_{12}p(1)f_1(\mathbf{x}),$$

so kann man es willkürlich einer der beiden Gruppen zuordnen.

Spezialfälle

- 1. $c_{r\hat{r}} = c, \ r \neq \hat{r}$, d.h. jede Verwechslung hat denselben Schaden
- → Bayes-Zuordnung
- 2. $c_{r\hat{r}} = \frac{c}{p(r)}$, d.h. Schaden ist proportional zur Größe der Klassen
- \rightarrow ML-Zuordnung

Diskriminanzanalyse bei normalverteilten Grundgesamtheiten

Klassifikation unter Normalverteilung

► Annahme: **x**|*r* multivariat normalverteilt mit Dichte:

$$f(\mathbf{x}|\boldsymbol{\mu}_r, \boldsymbol{\Sigma}_r) = \frac{1}{(2\pi)^{p/2} \mid \boldsymbol{\Sigma}_r \mid^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_r)^{\top} \boldsymbol{\Sigma}_r^{-1} (\mathbf{x} - \boldsymbol{\mu}_r)\right\}$$

 Betrachte Bayes-Zuordnungsregel ohne Kosten und zugehörige Diskriminanzfunktion

$$d_r(\mathbf{x}) = \log(f(\mathbf{x}|r)) + \log(p(r))$$

$$= -\frac{1}{2}(\mathbf{x} - \mu_r)^{\top} \Sigma_r^{-1}(\mathbf{x} - \mu_r) - \frac{1}{2}\log(|\Sigma_r|)$$

$$-\frac{p}{2}\log(2\pi) + \log(p(r))$$

1. Spezialfall: $\mathbf{x}|r \sim N_p(\mu_r, \sigma^2 \mathbf{I})$

Diskriminanzfunktion:

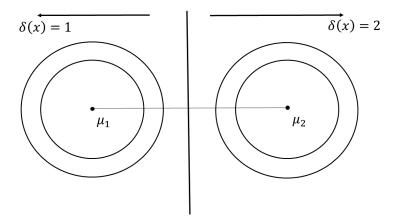
$$d_r(\mathbf{x}) = -\frac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_r)^{\top}(\mathbf{x} - \boldsymbol{\mu}_r) - \frac{1}{2}\log(|\sigma^2\mathbf{I}|) + \log(p(r))$$

 \rightarrow Vergleich zweier Klassen r und \tilde{r} mit $p(r) = p(\tilde{r})$:

$$\begin{aligned} d_r(\mathbf{x}) & \geq d_{\tilde{r}}(\mathbf{x}) \Leftrightarrow \\ -\frac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_r)^{\top}(\mathbf{x} - \boldsymbol{\mu}_r) & \geq -\frac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_{\tilde{r}})^{\top}(\mathbf{x} - \boldsymbol{\mu}_{\tilde{r}}) \\ -\frac{1}{2\sigma^2}||\mathbf{x} - \boldsymbol{\mu}_r||^2 & \geq -\frac{1}{2\sigma^2}||\mathbf{x} - \boldsymbol{\mu}_{\tilde{r}}||^2 \\ ||\mathbf{x} - \boldsymbol{\mu}_r||^2 & \leq ||\mathbf{x} - \boldsymbol{\mu}_{\tilde{r}}||^2 \end{aligned}$$

→ Objekt wird Klasse mit geringstem Abstand zum Erwartungswert zugeordnet (Minimum-Distanz-Regel)

1. Spezialfall: Skizze



2. Spezialfall: $\mathbf{x}|r \sim N_p(\boldsymbol{\mu}_r, \boldsymbol{\Sigma})$

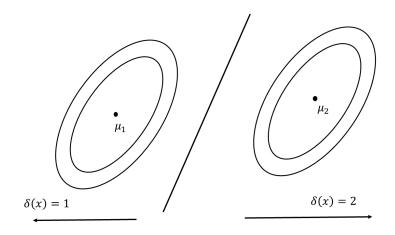
Diskriminanzfunktion:

$$\begin{aligned} d_r(\mathbf{x}) &= -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_r)^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_r) - \frac{1}{2} \log(|\boldsymbol{\Sigma}|) + \log(\boldsymbol{p}(r)) \\ &= -\frac{1}{2} ||\mathbf{x} - \boldsymbol{\mu}_r||_{\boldsymbol{\Sigma}^{-1}}^2 - \frac{1}{2} \log(|\boldsymbol{\Sigma}|) + \log(\boldsymbol{p}(r)) \\ &= -\frac{1}{2} \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x} + \mathbf{x}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_r - \frac{1}{2} \boldsymbol{\mu}_r^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_r - \frac{1}{2} \log(|\boldsymbol{\Sigma}|) + \log(\boldsymbol{p}(r)) \end{aligned}$$

→ Ordne Objekt der Klasse zu, zu der x die kleinste Mahalanobis-Distanz hat Beachte: Terme, die nicht von r abhängen, sind irrelevant:

$$d_r(\mathbf{x}) = \mathbf{x}^{\top} \Sigma^{-1} \mu_r - \frac{1}{2} \mu_r^{\top} \Sigma^{-1} \mu_r + \log(p(r))$$

2. Spezialfall: Skizze



2. Spezialfall: Beispiel mit 2 Gruppen

- ► Annahme: p(1) = p(2) (ML-Zuordnung)
- Diskriminanzfunktion für die 1. Gruppe:

$$d_1(\mathbf{x}) = \mathbf{x}^{\top} \Sigma^{-1} \mu_1 - \frac{1}{2} \mu_1^{\top} \Sigma^{-1} \mu_1$$

▶ Diskriminanzfunktion für die 2. Gruppe:

$$d_2(\mathbf{x}) = \mathbf{x}^{\mathsf{T}} \Sigma^{-1} \mu_2 - \frac{1}{2} \mu_2^{\mathsf{T}} \Sigma^{-1} \mu_2$$

 \rightarrow Ordne ein Objekt Gruppe 1 zu, wenn gilt $d_1(\mathbf{x}) > d_2(\mathbf{x})$ bzw. $d_1(\mathbf{x}) - d_2(\mathbf{x}) > 0$

$$\begin{split} & \boldsymbol{x}^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_{1} - \frac{1}{2} \boldsymbol{\mu}_{1}^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_{1} - \boldsymbol{x}^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_{2} + \frac{1}{2} \boldsymbol{\mu}_{2}^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_{2} > 0 \iff \\ & \left(\boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_{1} - \boldsymbol{\mu}_{2}) \right)^{\top} \boldsymbol{x} - \frac{1}{2} \left(\boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_{1} - \boldsymbol{\mu}_{2}) \right)^{\top} (\boldsymbol{\mu}_{1} + \boldsymbol{\mu}_{2}) > 0 \iff \\ & \left(\boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_{1} - \boldsymbol{\mu}_{2}) \right)^{\top} \boldsymbol{x} > \frac{1}{2} \left(\boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_{1} - \boldsymbol{\mu}_{2}) \right)^{\top} (\boldsymbol{\mu}_{1} + \boldsymbol{\mu}_{2}) \end{split}$$

Multivariate Verfahren – SS 21 Diskriminanzanalyse – Folie 41/71

Lineare vs. Quadratische Diskriminanzfunktion

▶ $\mathbf{x}|r \sim N_p(\mu_r, \Sigma)$ mit Diskriminanzfunktion:

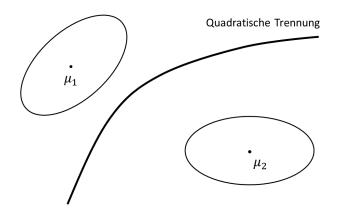
$$d_r(\mathbf{x}) = \mathbf{x}^{\top} \Sigma^{-1} \mu_r - \frac{1}{2} \mu_r^{\top} \Sigma^{-1} \mu_r + \log(p(r))$$
$$= \mathbf{a}_r^{\top} \mathbf{x} + a_{r0}$$

- → lineare Funktion in x
- ▶ 3. Fall: $\mathbf{x}|r \sim N_p(\mu_r, \Sigma_r)$
- → kein Term der log-Dichte kann vernachlässigt werden
- → Diskriminanzfunktion:

$$d_r(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{A}_r \mathbf{x} + \mathbf{a}_r^{\top} \mathbf{x} + a_{r0}$$

→ quadratische Funktion in x

3. Fall: Skizze

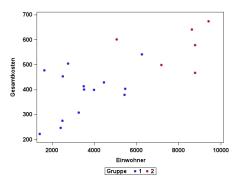


Geschätzte Zuordnungregel

- Ausgangspunkt bisher: wahre Verteilung zur Bestimmung der Zuordnung bekannt
- ▶ Jetzt: Daten $\mathbf{x}_{(1)}^r, \dots, \mathbf{x}_{(n_r)}^r, r = 1, \dots, g$ gegeben (Lernstichprobe)
- ightarrow geschätzte Diskriminanzfunktion durch Einsetzen der Schätzer $\hat{\mu}_r = \bar{\mathbf{x}}_r$ und $\hat{\Sigma}_r = \mathbf{S}_r$
- \rightarrow Für neue Beobachtung $\tilde{\mathbf{x}}$ gilt:

$$\hat{\delta}(\tilde{\mathbf{x}}) = r \iff d_r(\tilde{\mathbf{x}} \,|\, \bar{\mathbf{x}}_r, \mathbf{S}_r) = \max_j d_j(\tilde{\mathbf{x}} \,|\, \bar{\mathbf{x}}_j, \mathbf{S}_j)$$

- Betrachtung von 20 Zweigstellen, die sich in 2 Gruppen einteilen lassen
- 14 haben hohen Marktanteil und ein überdurchschnittliches Darlehens- und Kreditgeschäft
- 6 sind technisch gut ausgestattet, besitzen überdurchschnittliches Einlage- und Kreditgeschäft und hohe Mitarbeiterzahl



Ordne Objekt der ersten Gruppe zu, wenn gilt:

$$\left(\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)\right)^{\top} \boldsymbol{x} > \frac{1}{2} \left(\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)\right)^{\top} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)$$

Geschätzte Erwartungswerte:

$$\hat{\mu}_1 = \bar{\mathbf{x}}_1 = \begin{pmatrix} 3510.4 \\ 390.2 \end{pmatrix} \quad \hat{\mu}_2 = \bar{\mathbf{x}}_2 = \begin{pmatrix} 7975.2 \\ 577.5 \end{pmatrix}$$

Geschätzte Kovarianzmatrix:

$$\hat{\Sigma} = \mathbf{S} = \begin{pmatrix} 2267168.12 & 49088.07 \\ 49088.07 & 8381.77 \end{pmatrix}$$

Ordne Beobachtung x der ersten Gruppe zu, falls gilt:

$$\left(\boldsymbol{S}^{-1}(\boldsymbol{\bar{x}}_1 - \boldsymbol{\bar{x}}_2)\right)^{\top}\boldsymbol{x} > \frac{1}{2}\left(\boldsymbol{S}^{-1}(\boldsymbol{\bar{x}}_1 - \boldsymbol{\bar{x}}_2)\right)^{\top}(\boldsymbol{\bar{x}}_1 + \boldsymbol{\bar{x}}_2)$$

Inverse geschätzte Kovarianzmatrix:

$$\mathbf{S}^{-1} = \begin{pmatrix} 0.00000051 & -0.00000296 \\ -0.00000296 & 0.00013663 \end{pmatrix}$$

Mittelwertsdifferenz:

$$\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 = \begin{pmatrix} -4464.8 \\ -187.2 \end{pmatrix}$$

Daraus ergibt sich:

$$\mathbf{S}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = \begin{pmatrix} -0.00170 \\ -0.01237 \end{pmatrix}$$

Klassifizieren eine Zweigstelle mit dem Merkmalsvektor

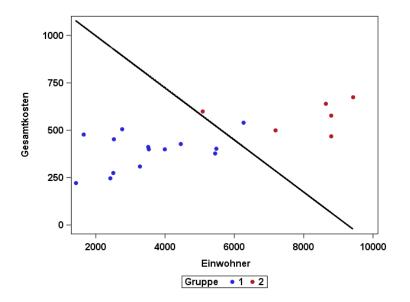
$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

zur Gruppe 1, falls gilt:

$$\begin{pmatrix} -0.0017 & -0.01237 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} > \begin{pmatrix} -0.0017 & -0.01237 \end{pmatrix} \begin{pmatrix} 5742.8 \\ 483.8 \end{pmatrix}$$

→ Vereinfachen zu:

$$0.0017x_1 + 0.01237x_2 < 15.747$$



Eigenschaften

- Gesamtfehler für Bayes-Zuordnung unter Normalverteilung:
 - $\varepsilon(\delta(\text{quadratisch})) \le \varepsilon(\delta(\text{linear}))$
 - $\triangleright \ \varepsilon(\hat{\delta}) \ge \varepsilon(\delta)$
- ▶ Erwartungswert $\mathbb{E}_L(\varepsilon(\hat{\delta}))$ über mehrere Lernstichproben
 - $\blacktriangleright \ \mathbb{E}_{L}(\varepsilon(\hat{\delta})) \geq \varepsilon(\delta)$
 - keine Dominanz der quadratischen Diskriminanzfunktion, d.h.:

$$\mathbb{E}_{L}(\varepsilon(\hat{\delta}(\mathsf{quadratisch}))) \nleq \mathbb{E}_{L}(\varepsilon(\hat{\delta}(\mathsf{linear})))$$

Diskriminanzanalyse nach Fisher

Diskriminanzanalyse nach Fisher (Zwei-Klassen-Fall)

- ▶ Gegeben: Daten $\mathbf{x}^1_{(1)}, \dots, \mathbf{x}^1_{(n_1)}$ und $\mathbf{x}^2_{(1)}, \dots, \mathbf{x}^2_{(n_2)}$
- ► Ziel: Finde Projektion, d.h. eine Linearkombination

$$y = \mathbf{a}^{\top} \mathbf{x}$$
, mit $\|\mathbf{a}\| = 1$,

sodass die beiden Klassen bestmöglich getrennt werden

- Anforderungen:
 - Streuung zwischen Gruppen möglichst groß
 - Streuung innerhalb der Gruppen möglichst klein

Grafische Veranschaulichung



Quelle: R. Schlittgen: Multivariate Statistik. 2009, Oldenbourg

Kriterium von Fisher

Maximiere folgendes Kriterium, um eine maximale Trennung der beiden Klassen zu erzielen:

$$Q(\mathbf{a}) = rac{(ar{y}_1 - ar{y}_2)^2}{w_1^2 + w_2^2} \,,$$

wobei

$$\bar{y}_r = \frac{1}{n_r} \sum_{i=1}^{n_r} \mathbf{a}^\top \mathbf{x}_{(i)}^r = \mathbf{a}^\top \bar{\mathbf{x}}_r, \quad r = 1, 2,$$

$$w_r^2 = \sum_{i=1}^{n_r} (\mathbf{a}^\top \mathbf{x}_{(i)}^r - \mathbf{a}^\top \bar{\mathbf{x}}_r)^2, \quad r = 1, 2.$$

Kriterium von Fisher

Es gilt:

$$\begin{aligned} w_1^2 + w_2^2 &= \sum_{r=1}^2 \sum_{i=1}^{n_r} (\mathbf{a}^\top \mathbf{x}_{(i)}^r - \mathbf{a}^\top \bar{\mathbf{x}}_r)^2 \\ &= \mathbf{a}^\top \sum_{r=1}^2 \sum_{i=1}^{n_r} (\mathbf{x}_{(i)}^r - \bar{\mathbf{x}}_r) (\mathbf{x}_{(i)}^r - \bar{\mathbf{x}}_r)^\top \mathbf{a} \\ &= \mathbf{a}^\top \mathbf{W} \mathbf{a} \end{aligned}$$

Und damit:

$$Q(\mathbf{a}) = \frac{(\mathbf{a}^{\top}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2))^2}{\mathbf{a}^{\top}\mathbf{W}\,\mathbf{a}} \rightarrow \max_{\mathbf{a}\neq\mathbf{0}}$$

Kriterium nach Fisher

Maximierung durch Bilden der Ableitung und lösen der Gleichung: $\frac{\partial Q(\mathbf{a})}{\partial \mathbf{a}} = 0$.

Damit gilt:

$$\begin{array}{lll} \frac{\partial \textit{Q}(\textbf{a})}{\partial \textbf{a}} & = & \frac{2(\textbf{a}^{\top}\bar{\textbf{x}}_{1} - \textbf{a}^{\top}\bar{\textbf{x}}_{2})(\bar{\textbf{x}}_{1} - \bar{\textbf{x}}_{2})\textbf{a}^{\top}\textbf{W}\textbf{a} - 2\textbf{W}\textbf{a}(\textbf{a}^{\top}\bar{\textbf{x}}_{1} - \textbf{a}^{\top}\bar{\textbf{x}}_{2})^{2}}{(\textbf{a}^{\top}\textbf{W}\textbf{a})^{2}} \\ & = & 0 \iff \end{array}$$

$$\begin{split} (\bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2) \boldsymbol{a}^\top \boldsymbol{W} \boldsymbol{a} - \boldsymbol{W} \boldsymbol{a} (\boldsymbol{a}^\top \bar{\boldsymbol{x}}_1 - \boldsymbol{a}^\top \bar{\boldsymbol{x}}_2) &= 0 \Leftrightarrow \\ \boldsymbol{W} \boldsymbol{a} \underbrace{\left(\frac{\boldsymbol{a}^\top \bar{\boldsymbol{x}}_1 - \boldsymbol{a}^\top \bar{\boldsymbol{x}}_2}{\boldsymbol{a}^\top \boldsymbol{W} \boldsymbol{a}} \right)}_{konst} &= \bar{\boldsymbol{x}}_1 - \bar{\boldsymbol{x}}_2 \end{split}$$

$$oldsymbol{ iny} o \mathsf{W}$$
ähle $\mathbf{a} = \mathbf{W}^{-1}(ar{\mathbf{x}}_1 - ar{\mathbf{x}}_2)$

Vergleich zur linearen Diskriminanzanalyse

Unter Normalverteilungsannahme mit gleichen Kovarianzmatrizen gilt für den Vergleich zweier Diskriminanzfunktionen

$$d_1(\mathbf{x}) = d_2(\mathbf{x})$$

$$\Leftrightarrow \mathbf{a}_1^{\mathsf{T}} \mathbf{x} + a_{10} = \mathbf{a}_2^{\mathsf{T}} \mathbf{x} + a_{20}$$

$$\Leftrightarrow (\mathbf{a}_1 - \mathbf{a}_2)^{\mathsf{T}} \mathbf{x} = a_{20} - a_{10}$$

mit
$$\mathbf{a}_1 = \Sigma^{-1} \mu_1$$
 und $\mathbf{a}_2 = \Sigma^{-1} \mu_2$.
 \rightarrow Schätzung aus Datensatz: $(\mathbf{a}_1 - \mathbf{a}_2) = \mathbf{S}^{-1} (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) \rightarrow$
Kriterium nach Fisher mit $\mathbf{S} = \frac{1}{n_1 + n_2 - 2} \mathbf{W}$

Beispiel: Studienanfänger

Geschlecht	MatheLK	MatheNote	Abitur88	Gruppe
0	0	3	0	2
0	0	4	0	2
0	0	4	0	2
0	0	4	0	2
1	0	3	0	2
	•••	•••		

Mittelwerte der Gruppen:

$$\bar{\boldsymbol{x}}_1 = \begin{pmatrix} 0.556 \\ 0.889 \\ 2.667 \\ 0.333 \end{pmatrix} \quad \bar{\boldsymbol{x}}_2 = \begin{pmatrix} 0.455 \\ 0.273 \\ 3.182 \\ 0.364 \end{pmatrix}$$

Beispiel: Studienanfänger

$$\begin{split} \boldsymbol{S}_1 &= \begin{pmatrix} 0.278 & -0.056 & 0.208 & 0.042 \\ -0.056 & 0.111 & -0.167 & -0.083 \\ 0.208 & -0.167 & 1.000 & 0.125 \\ 0.042 & -0.083 & 0.125 & 0.250 \end{pmatrix} \\ \boldsymbol{S}_2 &= \begin{pmatrix} 0.273 & 0.064 & -0.191 & 0.218 \\ 0.064 & 0.218 & -0.255 & 0.091 \\ -0.191 & -0.255 & 0.564 & -0.173 \\ 0.218 & 0.091 & -0.173 & 0.255 \end{pmatrix} \\ \boldsymbol{W} &= \begin{pmatrix} 4.954 & 0.192 & -0.246 & 2.516 \\ 0.192 & 3.068 & -3.886 & 0.246 \\ -0.246 & -3.886 & 13.640 & -0.730 \\ 2.516 & 0.246 & -0.730 & 4.550 \end{pmatrix} \\ \boldsymbol{W}^{-1} &= \begin{pmatrix} 0.2812 & -0.0145 & -0.0074 & -0.1559 \\ -0.0145 & 0.5108 & 0.1455 & 0.0037 \\ -0.0074 & 0.1455 & 0.1154 & 0.0147 \\ -0.1559 & 0.0037 & 0.0147 & 0.3082 \end{pmatrix} \end{split}$$

Beispiel: Studienanfänger

Es ergibt sich

$$\mathbf{a} = \mathbf{W}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2) = \begin{pmatrix} 0.028 \\ 0.238 \\ 0.029 \\ -0.030 \end{pmatrix}$$

$$ightarrow {f a}^{ op} {f ar x}_1 = ar y_1 = 0.295, {f a}^{ op} {f ar x}_2 = ar y_2 = 0.159$$

→ Ordne Objekt Gruppe 1 zu, wenn gilt:

$$|\mathbf{a}^{\top}\mathbf{x} - \bar{y}_1| < |\mathbf{a}^{\top}\mathbf{x} - \bar{y}_2|.$$

Erster Student:

$$\mathbf{x} = \begin{pmatrix} 1 \\ 0 \\ 4 \\ 1 \end{pmatrix}$$

Es gilt $\mathbf{a}^{\top}\mathbf{x} = 0.114$. \rightarrow Gruppe 2

Diskriminanzanalyse nach Fisher (Mehr-Klassen-Fall)

- ▶ Gegeben: Daten $\mathbf{x}_{(1)}^r, \dots, \mathbf{x}_{(n_r)}^r, r = 1, \dots, g$
- ► Gesucht: Projektion $y = \mathbf{a}^{\top} \mathbf{x}$, welche durch Maximierung von

$$Q(\mathbf{a}) = \frac{\sum_{r=1}^{g} n_r (\bar{y}_r - \bar{y})^2}{\sum_{r=1}^{g} w_r^2}$$

bestimmt ist, wobei

$$\bar{y} = \frac{1}{n} \sum_{r=1}^{g} n_r \bar{y}_r$$

Kriterium nach Fisher

▶ Zähler von Q(a):

$$\begin{split} \sum_{r=1}^g n_r (\bar{y}_r - \bar{y})^2 &= \sum_{r=1}^g n_r (\mathbf{a}^\top \bar{\mathbf{x}}_r - \mathbf{a}^\top \bar{\mathbf{x}})^2 \\ &= \mathbf{a}^\top \sum_{r=1}^g n_r (\bar{\mathbf{x}}_r - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_r - \bar{\mathbf{x}})^\top \mathbf{a} = \mathbf{a}^\top \mathbf{B} \mathbf{a} \end{split}$$

Mit dem Resultat von Folie 54:

$$Q(\mathbf{a}) = rac{\mathbf{a}^{ op} \mathbf{B} \, \mathbf{a}}{\mathbf{a}^{ op} \mathbf{W} \, \mathbf{a}} \,
ightarrow \, \max_{\mathbf{a}
eq \mathbf{0}}$$

Kriterium nach Fisher

Lösung mithilfe der Gleichung: $\frac{\partial Q(\mathbf{a})}{\partial \mathbf{a}} = 0$

$$\begin{split} \frac{\partial \textit{Q}(\textbf{a})}{\partial \textbf{a}} &= \frac{2 \textbf{B} \textbf{a} (\textbf{a}^\top \textbf{W} \textbf{a}) - 2 (\textbf{a}^\top \textbf{B} \textbf{a}) \textbf{W} \textbf{a}}{(\textbf{a}^\top \textbf{W} \textbf{a})^2} \\ &= \frac{2 (\textbf{a}^\top \textbf{W} \textbf{a}) [\textbf{B} \textbf{a} - \frac{\textbf{a}^\top \textbf{B} \textbf{a}}{\textbf{a}^\top \textbf{W} \textbf{a}} \textbf{W} \textbf{a}]}{(\textbf{a}^\top \textbf{W} \textbf{a})^2} \\ &= \frac{2 (\textbf{B} \textbf{a} - \textit{Q}(\textbf{a}) \textbf{W} \textbf{a})}{\textbf{a}^\top \textbf{W} \textbf{a}} = 0 \end{split}$$

$$\Leftrightarrow \mathbf{Ba} = Q(\mathbf{a})\mathbf{Wa}$$

$$\Leftrightarrow \mathbf{W}^{-1}\mathbf{Ba} = \underbrace{Q(\mathbf{a})}_{\mathsf{Skalar}\,\lambda} \mathbf{a} = \lambda \mathbf{a}$$

→ Es ergibt sich ein verallgemeinertes Eigenwertproblem!

Lösung des Eigenwertproblems

Generelle Form verallgemeinertes Eigenwertproblem:

$$\mathbf{W}^{-1}\mathbf{Ba} = \lambda \mathbf{a}$$

wobei **W** und **B** symmetrisch und **W** außerdem positiv definit

- ► Möglicher Lösungsansatz:
- ➤ Zerlege W mittels Cholesky-Zerlegung: W = LL^T
- ▶ Eigenwerte der Matrix $\mathbf{H} := \mathbf{L}^{-1}\mathbf{B}(\mathbf{L}^{-1})^{\top}$ sind identisch zu Eigenwerten von $\mathbf{W}^{-1}\mathbf{B}$

Lösung des Eigenwertproblems

- ▶ $\operatorname{rg}(\mathbf{W}) = p \operatorname{und} \operatorname{rg}(\mathbf{B}) = q \leq \min\{p, g 1\}$
- ightarrow **W**⁻¹**B** hat höchstens q Eigenwerte $\lambda_1, \ldots, \lambda_q$ mit zugehörigen Eigenvektoren $\mathbf{a}_1, \ldots, \mathbf{a}_q$
 - ▶ Lösungen:

$$\lambda_r = rac{\mathbf{a}_r^{\mathsf{T}} \mathbf{B} \, \mathbf{a}_r}{\mathbf{a}_r^{\mathsf{T}} \mathbf{W} \, \mathbf{a}_r}, \quad r = 1, \dots, q,$$

und die "kanonischen Variablen"

$$y_r = \mathbf{a}_r^{\top} \mathbf{x}, \quad r = 1, \dots, q$$

Praktisches Vorgehen

- ▶ Ordne die Eigenwerte $\lambda_1, \ldots, \lambda_q$ der Größe nach und verwende alle oder nur $m \le q$ Komponenten (Projektionsrichtungen)
- Betrachte die Entscheidungsregel:

$$\delta(\mathbf{x}) = r \Leftrightarrow \sum_{r=1}^{m} (\mathbf{a}_r \mathbf{x} - \mathbf{a}_r^{\top} \bar{\mathbf{x}}_r)^2 = \min_{j} \sum_{r=1}^{m} (\mathbf{a}_r \mathbf{x} - \mathbf{a}_r^{\top} \bar{\mathbf{x}}_j)^2$$

 Beachte: Es kann (wieder) gezeigt werden, dass dieses Kriterium äquivalent zur ML-Zuordnung unter Normalverteilungsannahme mit gleichen Kovarianzmatrizen ist

k-nächste Nachbarn

Klassifikation anhand der k-nächsten Nachbarn

- ▶ Betrachte Gesamtstichprobe (\mathbf{x}_i, Y_i) , i = 1, ..., n
- ► Bestimme zu jedem Merkmalsvektor **x**_i diejenigen Merkmalsvektoren, die am nähesten an **x**_i liegen
- Berechne dafür die Distanzen

$$d(\mathbf{x}_i,\mathbf{x}_s), \quad i \neq s,$$

über ein geeignetes Distanzmaß *d*, z.B. die quadrierte euklidische Distanz

Klassifikation anhand der k-nächsten Nachbarn

- ▶ Bestimme zu x₁ die k nächsten Nachbarn
- ▶ Bezeichnung: $\mathbf{x}_{(1)}, \dots, \mathbf{x}_{(k)}$ mit

$$d(\mathbf{x}_i, \mathbf{x}_{(1)}) \leq d(\mathbf{x}_i, \mathbf{x}_{(2)}) \leq \ldots \leq d(\mathbf{x}_i, \mathbf{x}_{(k)}).$$

▶ Bezeichnet $Y_{(1)}, \ldots, Y_{(k)}$ die Klasse zu $\mathbf{x}_{(1)}, \ldots, \mathbf{x}_{(k)}$, so ergibt sich die Zuordnungsregel:

$$\delta(\mathbf{x}_i) = r \Leftrightarrow r$$
 ist die häufigste Klasse in $\{Y_{(1)}, \dots, Y_{(k)}\}$

k-nächsten Nachbarn: Eigenschaften

- ▶ Verteilungsfreies bzw. nichtparametrisches Verfahren, d.h. es gibt keine Annahme zur Verteilung von x|r
- Stellschrauben des Verfahrens sind die Distanz d und die Anzahl der nächsten Nachbarn k

Logistische Diskriminanzanalyse

Logistische Regression (Zwei-Klassen-Fall)

Ausgehend von Zufallsvektoren (x, Y) postuliert man für die a posteriori-Wahrscheinlichkeiten:

$$P(Y = 1|\mathbf{x}) = \frac{\exp(\beta_0 + \mathbf{x}^\top \boldsymbol{\beta})}{1 + \exp(\beta_0 + \mathbf{x}^\top \boldsymbol{\beta})} \quad \text{und}$$

$$P(Y = 2|\mathbf{x}) = 1 - P(Y = 1|\mathbf{x}) = \frac{1}{1 + \exp(\beta_0 + \mathbf{x}^\top \boldsymbol{\beta})}$$

Äquivalent kann postuliert werden:

$$\log\left(\frac{f(\mathbf{x}|1)}{f(\mathbf{x}|2)}\right) = \tilde{\beta}_0 + \mathbf{x}^\top \boldsymbol{\beta}, \quad \text{wobei} \quad \tilde{\beta}_0 = \beta_0 + \log\left(\frac{p(1)}{p(2)}\right)$$

Logistische Regression: Zuordnungsregeln

Diskriminanzfunktion:

$$d(\mathbf{x}) = \ln \left(\frac{P(Y=1|\mathbf{x})}{P(Y=2|\mathbf{x})} \right) = \beta_0 + \mathbf{x}^{\top} \boldsymbol{\beta}$$

→ Ordne Objekt mit Merkmalsvektor x gemäß Bayes-Zuordnungsregel Klasse 1 zu, falls

$$d(\mathbf{x}) \geq 0$$

- Ordne das Objekt ansonsten Klasse 2 zu
- ► Ersetzen von β_0 durch $\tilde{\beta}_0$ ergibt Zuordnung gemäß ML-Zuordnungsregel

Logistische Regression: Eigenschaften

- Keine Annahme bzgl. Verteilung von x|r
- ► Einfache Verallgemeinerung für g Klassen möglich
- Ansatz der logistischen Regression ist für Reihe von Klassendichten erfüllt, z.B. für Multinomialverteilung mit gleichen Kovarianzmatrizen
- Parameter β_0 und β sind in der Regel unbekannt und müssen geschätzt werden (analog zur Beschreibung auf Folie 44).