## **Multivariate Verfahren**

## Multivariate Verteilungen

Annika Hoyer

Sommersemester 2021

## Multivariate Verteilungen - Inhalt

## Wiederholung: Eindimensionale Zufallsvariablen

Verteilungsfunktion Wahrscheinlichkeitsfunktion, Dichte Kennzahlen von Zufallsvariablen

#### Multivariate Zufallsvariablen

Definition, Gemeinsame Verteilung Erwartungswertvektor Kovarianzmatrix, Korrelationsmatrix

Multivariate Normalverteilung Beispiele

Weitere multivariate Verteilungen

Wiederholung: Eindimensionale Zufallsvariablen

## Zufallsvariablen

In der Statistik werden Daten mit Hilfe von Zufallsvariablen modelliert:

- Diskrete Zufallsvariablen nehmen Werte in endlicher oder höchstens abzählbar unendlicher Menge an (endliche Menge, natürliche Zahlen, ganze Zahlen, ...)
- ▶ Stetige Zufallsvariablen nehmen Werte auf einem Intervall oder den gesamten reellen Zahlen an. Wegen des überabzählbaren Wertebereichs gilt P(X = x) = 0 für alle  $x \in \mathbb{R}$ , d.h. die Wahrscheinlichkeit, dass eine stetige Zufallsvariable X einen Wert x genau annimmt, ist Null.

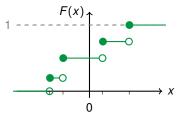
## Verteilungsfunktion

## Definition: Verteilungsfunktion

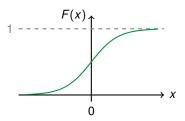
Für eine Zufallsvariable X heißt die Funktion

$$F(x) = P(X \le x), \quad x \in \mathbb{R}$$

**Verteilungsfunktion** von *X*. Durch sie ist *X* eindeutig bestimmt.



Verteilungsfunktion einer diskreten Zufallsvariable



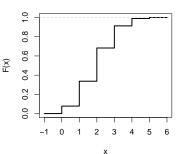
Verteilungsfunktion einer stetigen Zufallsvariable

## Beispiel 1 – Diskrete Zufallsvariablen

## **Binomialverteilte Zufallsvariablen:** $X \sim Bin(n, p)$

- ► Wertebereich: 0, 1 . . . n (endliche Menge)
- ▶ Parameter:  $n \in \mathbb{N}$ ,  $p \in [0, 1]$
- Modellierung: Anzahl von Treffern (Münzwurf, Würfeln,...)

#### Verteilungsfunktion Bin(5, 0.4)

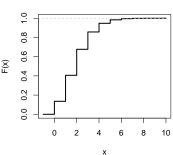


## Beispiel 1 – Diskrete Zufallsvariablen

## Poissonverteilte Zufallsvariablen: $X \sim Poi(\lambda)$

- ► Wertebereich: 0, 1, 2, ... (abzählbar unendliche Menge)
- ▶ Parameter:  $\lambda > 0$
- Modellierung: Zählvorgänge (Krankheitsfälle, Druckfehler,...)

#### Verteilungsfunktion Poi(2)

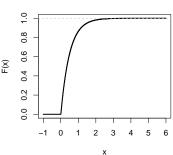


## Beispiel 1 – Stetige Zufallsvariablen

## **Exponentialverteilte Zufallsvariablen:** $X \sim \text{Exp}(\lambda)$

- Wertebereich:  $[0, \infty)$  (Intervall)
- ▶ Parameter:  $\lambda > 0$
- Modellierung: Zeitdauer (Wartezeit, Lebensdauer eines Produkts,...)

#### Verteilungsfunktion Exp(2)

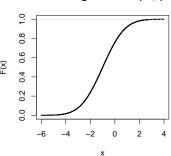


## Beispiel 1 – Stetige Zufallsvariablen

## Normalverteilte Zufallsvariablen: $X \sim N(\mu, \sigma^2)$

- ▶ Wertebereich: R (reelle Zahlen)
- ▶ Parameter:  $\mu \in \mathbb{R}$ ,  $\sigma^2 > 0$
- Modellierung: Abweichung von Messwerten von einem Mittelwert (Gewicht, Größe, Alter,...)

#### Verteilungsfunktion N(-1,2)



Statt über die Verteilungsfunktion *F* werden diskrete Zufallsvariablen häufig über ihre Wahrscheinlichkeitsfunktion, stetige Zufallsvariablen über ihre Dichte beschrieben.

#### Definition: Wahrscheinlichkeitsfunktion

Für eine diskrete Zufallsvariable X mit Wertebereich  $\{x_1, x_2, \ldots\}$  ist die **Wahrscheinlichkeitsfunktion** oder **Zähldichte** f an einem Wert  $x \in \mathbb{R}$  definiert durch

$$f(x) = \begin{cases} P(X = x_i) & x = x_i \text{ mit } i = 1, 2, \dots \\ 0 & \text{sonst.} \end{cases}$$

## Eigenschaften von Wahrscheinlichkeitsfunktionen:

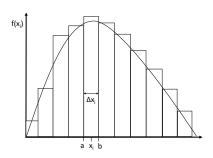
- ▶  $0 \le f(x) \le 1$  für alle  $x \in \mathbb{R}$ .

#### **Definition: Dichte**

Die **Dichte** f einer stetigen Zufallsvariablen X ist nichtnegativ (d.h.  $f(x) \ge 0$  für alle  $x \in \mathbb{R}$ ) und es gilt

$$P(a \le X \le b) = \int_a^b f(t)dt$$

für alle Intervalle  $[a, b] \subset \mathbb{R}$ .



- Variable stetig, falls zu zwei Werten a < b auch jeder Zwischenwert im Intervall
   [a, b] möglich ist</li>
- Wie werden die Wahrscheinlichkeiten bestimmt?
- Diskret: Summe über Wahrscheinlichkeiten für x<sub>i</sub> aus [a, b]
- Stetig: ausgehend von diskreter Größe
- $\rightarrow$  Fläche von Rechteck  $(a \cdot b)$ :  $P(X = x_i) = f(x_i) \Delta x_i$
- $\rightarrow \Delta x_i$  immer kleiner machen

#### **Definition: Dichte**

Die **Dichte** f einer stetigen Zufallsvariablen X ist nichtnegativ (d.h.  $f(x) \ge 0$  für alle  $x \in \mathbb{R}$ ) und es gilt

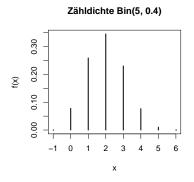
$$P(a \le X \le b) = \int_a^b f(t)dt$$

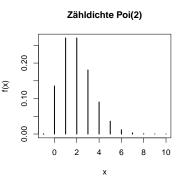
für alle Intervalle  $[a, b] \subset \mathbb{R}$ .

## Eigenschaften von Dichtefunktionen:

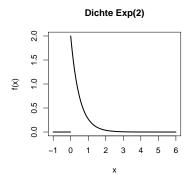
- $\int_{-\infty}^{\infty} f(t) dt = 1$
- ► Zusammenhang mit der Verteilungsfunktion:  $F(x) = P(-\infty \le X \le x) = \int_{-\infty}^{x} f(t) dt$
- → Die Verteilungsfunktion F ist Stammfunktion der Dichte f. Anders formuliert: Die Dichte f ist die Ableitung der Verteilungsfunktion F.

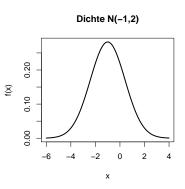
## Beispiel 1 – Diskrete Zufallsvariablen





## Beispiel 1 – Stetige Zufallsvariablen





## Kennzahlen von Zufallsvariablen

## Definition: Erwartungswert

Der **Erwartungwert** gibt an, welchen Wert eine Zufallsvariable *im Mittel* annimmt.

Für eine diskrete Zufallsvariable mit

Wahrscheinlichkeitsfunktion f und Wertebereich  $\{x_1, x_2, \ldots\}$  gilt

$$\mathbb{E}(X) = \sum_{i=1}^{\infty} x_i \cdot f(x_i).$$

Für eine stetige Zufallsvariable mit Dichte f gilt

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x \cdot f(x) \, dx.$$

 $\rightarrow \mathbb{E}(X)$  ist ein fester Wert (**nicht** zufällig!)

## Kennzahlen von Zufallsvariablen

## Rechenregeln:

Für Zufallsvariablen X, Y und Skalare (Zahlen)  $a, b \in \mathbb{R}$  gilt

$$\mathbb{E}(aX + b) = \sum_{i=1}^{\infty} ax_i f(x_i) + \sum_{i=1}^{\infty} bf(x_i)$$
$$= a \sum_{i=1}^{\infty} x_i f(x_i) + b \sum_{i=1}^{\infty} f(x_i)$$
$$= a \cdot \mathbb{E}(X) + b$$

$$\mathbb{E}(X+Y) = \mathbb{E}(X) + \mathbb{E}(Y)$$

## Kennzahlen von Zufallsvariablen

#### **Definition: Varianz**

#### Die Varianz

$$Var(X) = \mathbb{E}\left([X - \mathbb{E}(X)]^2\right)$$

beschreibt die erwartete quadratische Abweichung vom Erwartungswert.

## Varianzverschiebungssatz

$$\operatorname{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

#### Rechenregeln:

Für Zufallsvariablen X, Y und Skalare (Zahlen)  $a, b \in \mathbb{R}$  gilt

- $Var(aX + b) = a^2 Var(X)$
- Var(X + Y) = Var(X) + Var(Y) + 2Cov(X, Y)

## Beispiel 1

Erwartungwert und Varianz lassen sich häufig in Abhängigkeit der Verteilungsparameter darstellen.

## **Beispiele**

- ►  $X \sim \text{Bin}(n, p)$ :  $\mathbb{E}(X) = np$ , Var(X) = np(1 p)
- ▶  $X \sim \text{Poi}(\lambda)$ :  $\mathbb{E}(X) = \lambda$ ,  $\text{Var}(X) = \lambda$
- $ightharpoonup X \sim \mathsf{Exp}(\lambda)$ :  $\mathbb{E}(X) = \frac{1}{\lambda}$ ,  $\mathsf{Var}(X) = \frac{1}{\lambda^2}$
- $X \sim N(\mu, \sigma^2)$ :  $\mathbb{E}(X) = \mu$ ,  $Var(X) = \sigma^2$

# Multivariate Zufallsvariablen

## **Definition Zufallsvektor**

#### Definition: Zufallsvektor

Betrachte p Zufallsvariablen  $X_1 \dots X_p$ . Der p-dimensionale Vektor

$$\mathbf{X} = egin{pmatrix} X_1 \ dots \ X_{
ho} \end{pmatrix} = (X_1, \dots, X_{
ho})^{ op} \in \mathbb{R}^{
ho}$$

heißt Zufallsvektor oder p-dimensionale Zufallsvariable.

- Der Zufallsvektor X heißt diskret, falls alle Komponenten X<sub>i</sub> von X diskrete Zufallsvariablen sind.
- ▶ Der Zufallsvektor **X** heißt *stetig*, falls alle Komponenten  $X_i$  von **X** stetige Zufallsvariablen sind. Dann gilt  $P(X_1 = x_1, ..., X_p = x_p) = 0$  für alle  $\mathbf{x} = (x_1 ... x_p)^\top \in \mathbb{R}^p$ .

## Gemeinsame Verteilungsfunktion

## Definition: Gemeinsame Verteilungsfunktion

Für einen Zufallsvektor  $\mathbf{X} \in \mathbb{R}^p$  heißt die Funktion

$$F(\mathbf{x}) = F(x_1, \dots, x_p) = P(X_1 \le x_1 \dots X_p \le x_p), \quad \mathbf{x} \in \mathbb{R}^p$$

gemeinsame Verteilungsfunktion der Zufallsvariablen  $X_1 \dots X_p$ . Durch sie ist **X** eindeutig bestimmt.

Analog zum eindimensionalen Fall lassen sich für diskrete bzw. stetige Zufallsvektoren gemeinsame Wahrscheinlichkeitsfunktionen bzw. Dichten definieren.

## Gemeinsame Wahrscheinlichkeitsfunktion / Dichte

#### Definition: Gemeinsame Wahrscheinlichkeitsfunktion

Für einen diskreten Zufallsvektor  $\mathbf{X} \in \mathbb{R}^p$  mit Wertebereich  $\{\mathbf{x}_1, \mathbf{x}_2, \ldots\}$  ist die (gemeinsame)

Wahrscheinlichkeitsfunktion oder (gemeinsame) Zähldichte f an  $\mathbf{x} \in \mathbb{R}^p$  definiert durch

$$f(x) = \begin{cases} P(\mathbf{X} = \mathbf{x}_i) & \mathbf{x} = \mathbf{x}_i \text{ mit } i = 1, 2, \dots \\ 0 & \text{sonst.} \end{cases}$$

## Gemeinsame Wahrscheinlichkeitsfunktion / Dichte

#### Definition: Gemeinsame Dichte

Die (gemeinsame) **Dichte** f eines stetigen Zufallsvektors  $\mathbf{X} \in \mathbb{R}^p$  ist nichtnegativ (d.h.  $f(\mathbf{x}) \geq 0$  für alle  $\mathbf{x} \in \mathbb{R}^p$ ) und es gilt

$$P(\mathbf{a} \leq \mathbf{X} \leq \mathbf{b}) = P(a_1 \leq X_1 \leq b_1, \dots, a_p \leq X_p \leq b_p)$$

$$= \int_{a_p}^{b_p} \dots \int_{a_1}^{b_1} f(t_1, \dots, t_p) dt_1 \dots dt_p.$$

für alle  $\mathbf{a}, \mathbf{b} \in \mathbb{R}^p$  mit  $a_j < b_j, \ j = 1 \dots p$ .

## Gemeinsame Wahrscheinlichkeitsfunktion / Dichte

## Eigenschaften der gemeinsamen Dichte:

Wie im eindimensionalen Fall gilt:

$$\int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(t_1, \ldots, t_p) dt_1 \ldots dt_p = 1$$

Zusammenhang mit der gemeinsamen Verteilungsfunktion:

$$F(\mathbf{x}) = F(x_1, \dots, x_p) = P(X_1 \le x_1, \dots, X_p \le x_p)$$

$$= \int_{-\infty}^{x_p} \dots \int_{-\infty}^{x_1} f(t_1, \dots, t_p) dt_1 \dots dt_p = \int_{-\infty}^{\mathbf{x}} f(\mathbf{t}) d\mathbf{t}$$

## Erwartungswertvektor

## Definition: Erwartungswertvektor

Gegeben sei der Zufallsvektor  $\mathbf{X} = (X_1, \dots, X_p)^{\top} \in \mathbb{R}^p$ . Dann ist der **Erwartungswertvektor** von **X** definiert als

$$\mathbb{E}(\mathbf{X}) = egin{pmatrix} \mathbb{E}(X_1) \ dots \ \mathbb{E}(X_
ho) \end{pmatrix} \ .$$

#### Rechenregeln:

Für Zufallsvektoren **X**, **Y**  $\in \mathbb{R}^p$ , eine Matrix  $\mathbf{A} \in \mathbb{R}^{q \times p}$  und einen Vektor  $\mathbf{b} \in \mathbb{R}^q$  gilt

$$\blacktriangleright \mathbb{E}(\mathbf{X} + \mathbf{Y}) = \mathbb{E}(\mathbf{X}) + \mathbb{E}(\mathbf{Y})$$

$$ightharpoonup \mathbb{E}(\mathbf{A}\cdot\mathbf{X}+\mathbf{b}) = \mathbf{A}\cdot\mathbb{E}(\mathbf{X})+\mathbf{b}$$

## Kovarianz / Korrelation

#### Definition: Kovarianz

Die **Kovarianz** von zwei Zufallsvariablen *X* und *Y* ist definiert als

$$Cov(X, Y) = \mathbb{E}[(X - \mathbb{E}(X)) \cdot (Y - \mathbb{E}(Y))].$$

## Verschiebungssatz

$$Cov(X, Y) = \mathbb{E}(X \cdot Y) - \mathbb{E}(X)\mathbb{E}(Y)$$

Sind X und Y stetig, so gilt

$$Cov(X, Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} (x - \mathbb{E}(X))(y - \mathbb{E}(Y)) f(x, y) dxdy$$
$$\mathbb{E}(X \cdot Y) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} x \cdot y \cdot f(x, y) dxdy$$

## Kovarianz / Korrelation

#### **Definition: Korrelation**

Die **Korrelation** von zwei Zufallsvariablen *X* und *Y* ist definiert als

$$Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var(X) \cdot Var(Y)}}.$$

## Eigenschaften:

- Cov(X, Y) = Cov(Y, X) Corr(X, Y) = Corr(Y, X)
- ►  $Cov(X, X) = \mathbb{E}(X^2) [\mathbb{E}(X)]^2 = Var(X)$ ⇒ Corr(X, X) = 1
- ▶  $-1 \leq Corr(X, Y) \leq 1$
- ▶ X, Y unabhängig  $\Rightarrow$  Cov(X, Y) = 0 und Corr(X, Y) = 0 Umkehrung  $(\Leftarrow)$  gilt i.A. nicht!

## Kovarianz / Korrelation

## Rechenregeln:

Für Zufallsvariablen X, Y und Skalare a, b, c, d gilt

- $\quad \mathsf{Cov}(aX+c,bY+d) = ab\mathsf{Cov}(X,Y)$
- Corr(aX + c, bY + d) = Corr(X, Y)

#### Definition: Kovarianzmatrix

Gegeben sei der Zufallsvektor  $\mathbf{X} = (X_1, \dots, X_p)^{\top} \in \mathbb{R}^p$ . Dann ist die Kovarianzmatrix Cov $(\mathbf{X})$  von  $\mathbf{X}$  definiert durch

$$\operatorname{\mathsf{Cov}}(\mathbf{X}) = \Sigma = \mathbb{E}\left[ (\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))^{\top} \right]$$

$$= \begin{pmatrix} \operatorname{\mathsf{Cov}}(X_1, X_1) & \dots & \operatorname{\mathsf{Cov}}(X_1, X_p) \\ \vdots & \ddots & \vdots \\ \operatorname{\mathsf{Cov}}(X_p, X_1) & \dots & \operatorname{\mathsf{Cov}}(X_p, X_p) \end{pmatrix} \in \mathbb{R}^{p \times p}.$$

## Verschiebungssatz

$$\mathsf{Cov}(\mathbf{X}) = \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - \mathbb{E}(\mathbf{X})\mathbb{E}(\mathbf{X})^{\top}.$$

## Eigenschaften:

- Cov(X) ist quadratisch.
- Cov(X) ist symmetrisch.
- ▶ Die Diagonalelemente von Cov(X) sind gegeben durch

$$Cov(X_i, X_i) = Var(X_i) \ge 0$$
 für alle  $i = 1..., p$ .

Cov(X) ist positiv semidefinit.

## Rechenregeln:

Für einen Zufallsvektor  $\mathbf{X} \in \mathbb{R}^p$ , eine Matrix  $\mathbf{A} \in \mathbb{R}^{q \times p}$  und Vektoren  $\mathbf{a} \in \mathbb{R}^q$ ,  $\mathbf{b} \in \mathbb{R}^q$  gilt

- ►  $Var(\mathbf{a}^{\top}\mathbf{X}) = \mathbf{a}^{\top}Cov(\mathbf{X})\mathbf{a}$
- $\qquad \qquad \mathsf{Cov}(\mathbf{AX} + \mathbf{b}) = \mathbf{ACov}(\mathbf{X})\mathbf{A}^{\top}$

Welche Matrizen sind gültige Kovarianzmatrizen?

$$\begin{split} \Sigma_1 &= \begin{pmatrix} 0.2 & 0.5 \\ 0.2 & 0.3 \\ 0.5 & 0.3 \end{pmatrix} \quad \Sigma_2 = \begin{pmatrix} 0.5 & 0.7 & 0.9 \\ 0.3 & 0.9 & 0.3 \\ 0.9 & 0.7 & 0.5 \end{pmatrix} \\ \Sigma_3 &= \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix} \qquad \Sigma_4 = \begin{pmatrix} 0.5 & 0.7 & -0.9 \\ 0.7 & 0.9 & 0.3 \\ -0.9 & 0.3 & -0.5 \end{pmatrix} \end{split}$$

Für zwei Vektoren  $\mathbf{X} = (X_1, \dots, X_p)^{\top}$  und  $\mathbf{Y} = (Y_1, \dots, Y_q)$  gilt

$$\Sigma_{XY} = cov(\mathbf{X}, \mathbf{Y}) = \begin{pmatrix} cov(X_1, Y_1) & \dots & cov(X_1, Y_q) \\ \vdots & \vdots & \vdots \\ cov(X_p, Y_1) & \dots & cov(X_p, Y_q) \end{pmatrix}$$

 $\rightarrow \Sigma_{XY}$  ist i.A. nicht symmetrisch!

## Rechenregeln

$$\blacktriangleright \ \mathbb{E}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}$$

$$\begin{aligned} \mathsf{Cov}(\mathbf{X}) &= & \mathbb{E}\left((\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^{\top}\right) \\ &= & \mathbb{E}\left(\mathbf{X}\mathbf{X}^{\top} - \mathbf{X}\boldsymbol{\mu}^{\top} - \boldsymbol{\mu}\mathbf{X}^{\top} + \boldsymbol{\mu}\boldsymbol{\mu}^{\top}\right) \\ &= & \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - \mathbb{E}(\mathbf{X}\boldsymbol{\mu}^{\top}) - \mathbb{E}(\boldsymbol{\mu}\mathbf{X}^{\top}) + \mathbb{E}(\boldsymbol{\mu}\boldsymbol{\mu}^{\top}) \\ &= & \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - \mathbb{E}(\mathbf{X})\boldsymbol{\mu}^{\top} - \boldsymbol{\mu}\mathbb{E}(\mathbf{X}^{\top}) + \boldsymbol{\mu}\boldsymbol{\mu}^{\top}) \\ &= & \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - \boldsymbol{\mu}\boldsymbol{\mu}^{\top} - \boldsymbol{\mu}\boldsymbol{\mu}^{\top} + \boldsymbol{\mu}\boldsymbol{\mu}^{\top} \\ &= & \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - 2\boldsymbol{\mu}\boldsymbol{\mu}^{\top} + \boldsymbol{\mu}\boldsymbol{\mu}^{\top} \\ &= & \mathbb{E}(\mathbf{X}\mathbf{X}^{\top}) - \boldsymbol{\mu}\boldsymbol{\mu}^{\top} \end{aligned}$$

$$ightharpoonup \operatorname{Cov}(\mathbf{AX} + \mathbf{b}) = \mathbf{ACov}(\mathbf{X})\mathbf{A}^{\top}$$

$$\qquad \qquad \mathsf{Cov}(\mathbf{X},\mathbf{Y}) = \mathbb{E}\left((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))^{\top}\right)$$

$$extstyle \operatorname{\mathsf{Cov}}(\operatorname{\mathsf{AX}} + \operatorname{\mathsf{a}},\operatorname{\mathsf{BY}} + \operatorname{\mathsf{b}}) = \operatorname{\mathsf{ACov}}(\operatorname{\mathsf{X}},\operatorname{\mathsf{Y}})\operatorname{\mathsf{B}}^ op$$

## Zerlegung der Kovarianzmatrix

Es gilt:

$$\Sigma = \Sigma^{rac{1}{2}} \Sigma^{rac{1}{2}}$$
 bzw.  $\Sigma = \Sigma^{rac{1}{2}} \Sigma^{rac{T}{2}}$ 

und

$$\Sigma^{-1} = \Sigma^{-\frac{7}{2}} \Sigma^{-\frac{1}{2}}$$

Daraus resultiert:

$$\begin{array}{lll} \text{Cov}(\boldsymbol{\Sigma}^{-\frac{1}{2}}\boldsymbol{X}) & = & \boldsymbol{\Sigma}^{-\frac{1}{2}}\text{Cov}(\boldsymbol{X})\boldsymbol{\Sigma}^{-\frac{T}{2}} \\ & = & \boldsymbol{\Sigma}^{-\frac{1}{2}}\boldsymbol{\Sigma}\boldsymbol{\Sigma}^{-\frac{T}{2}} \\ & = & \boldsymbol{\Sigma}^{-\frac{1}{2}}\boldsymbol{\Sigma}^{\frac{1}{2}}\boldsymbol{\Sigma}^{\frac{T}{2}}\boldsymbol{\Sigma}^{-\frac{T}{2}} \\ & = & (\boldsymbol{\Sigma}^{\frac{1}{2}})^{-1}\boldsymbol{\Sigma}^{\frac{1}{2}}\boldsymbol{\Sigma}^{\frac{T}{2}}(\boldsymbol{\Sigma}^{\frac{T}{2}})^{-1} \\ & = & \boldsymbol{I} \end{array}$$

 $\Rightarrow \Sigma^{-\frac{1}{2}}(\mathbf{X} - \mathbb{E}(\mathbf{X}))$  hat Erwartungswert  $\mathbf{0}$  and Varianz  $\mathbf{I}$  (Multivariate Standardisierung).

## Spektralzerlegung

Es gilt:

$$\Sigma = \mathbf{P} \Lambda \mathbf{P}^{\top}$$
 und  $\Sigma^{-1} = \mathbf{P} \Lambda^{-1} \mathbf{P}^{\top}$ ,

wobei

 $\mathbf{P} = (\mathbf{p}_1, \dots, \mathbf{p}_p)^{\top}$ : Matrix der *orthonormalen* Eigenvektoren und

 $\Lambda = diag(\lambda_1, \dots, \lambda_p)$  : Diagonalmatrix der *geordneten* Eigenwerte.

#### Korrelationsmatrix

#### **Definition: Korrelationsmatrix**

Die **Korrelationsmatrix** eines Zufallsvektors  $\mathbf{X} \in \mathbb{R}^p$  ist wie folgt definiert:

$$\operatorname{\mathsf{Corr}}(\mathbf{X}) = egin{pmatrix} \operatorname{\mathsf{Corr}}(X_1, X_1) & \dots & \operatorname{\mathsf{Corr}}(X_1, X_p) \\ \vdots & \ddots & \vdots \\ \operatorname{\mathsf{Corr}}(X_p, X_1) & \dots & \operatorname{\mathsf{Corr}}(X_p, X_p) \end{pmatrix} \in \mathbb{R}^{p \times p}.$$

#### Eigenschaften:

- ► Corr(X) ist quadratisch
- Corr(X) ist symmetrisch
- ▶ Diagonale:  $Corr(X_i, X_i) = 1$  für alle i = 1..., p
- ► Corr(X) ist positiv semidefinit.

#### Korrelation und Unabhängigkeit

#### Definition: Unkorrelierte Zufallsvektoren

Seien  $\mathbf{Y} \in \mathbb{R}^r$  und  $\mathbf{Z} \in \mathbb{R}^q$  zwei Zufallsvektoren mit

$$\begin{split} \text{Cov}\left(\begin{pmatrix} \boldsymbol{Y} \\ \boldsymbol{Z} \end{pmatrix}\right) &= \begin{pmatrix} \text{Cov}(Y_1,Y_1) & \dots & \text{Cov}(Y_1,Y_r) & \text{Cov}(Y_1,Z_1) & \dots & \text{Cov}(Y_1,Z_q) \\ & \ddots & & \ddots & & \ddots \\ & \vdots & \ddots & & \ddots & & \ddots \\ & \vdots & \ddots & \vdots & \ddots & & \ddots \\ & \vdots & \ddots & \vdots & \ddots & \vdots & \ddots \\ & \vdots & \ddots & \ddots & \ddots$$

**Y** und **Z** heißen **unkorreliert**, falls  $\Sigma_{YZ} = \mathbf{0}$ .

#### Bemerkung:

Y und Z sind unabhängig ⇒ Y und Z sind unkorreliert. Die Umkehrung (←) gilt i.A. nicht!

# Multivariate Normalverteilung

#### Multivariate Normalverteilung

#### Definition: Multivariate Normalverteilung

Ein Zufallsvektor  $\mathbf{X} \in \mathbb{R}^p$  heißt **multivariat normalverteilt** mit Parametern  $\mu$  und  $\Sigma$ , falls er die folgende Dichte hat

$$f(\mathbf{x}) = \frac{1}{\left(\sqrt{2\pi}\right)^{\rho} \sqrt{\det(\Sigma)}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \mu)^{\top} \Sigma^{-1}(\mathbf{x} - \mu)\right\}$$

mit  $\mu \in \mathbb{R}^p$  und positiv definiter Matrix  $\Sigma \in \mathbb{R}^{p \times p}$ .

Die Schreibweise ist analog zur eindimensionalen Normalverteilung:

$$\mathbf{X} \sim \mathsf{N}_{p}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Häufig wird der Index *p* unterdrückt, wenn sich die Dimension aus dem Zusammenhang erschließen lässt.

#### Zusammenhang zur Spektralzerlegung

Es gilt (quadratische Form):

$$\begin{split} (\mathbf{X} - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) = & (\mathbf{X} - \boldsymbol{\mu})^{\top} \mathbf{P} \boldsymbol{\Lambda}^{-1} \mathbf{P}^{\top} (\mathbf{X} - \boldsymbol{\mu}) = \\ = & \mathbf{Y} \boldsymbol{\Lambda}^{-1} \mathbf{Y}^{\top} = \sum_{i=1}^{p} \frac{y_i^2}{\lambda_i} = \sum_{i=1}^{p} \left( \frac{y_i}{\sqrt{\lambda_i}} \right)^2 \end{split}$$

Die Isodensiten (Kurven mit derselben Dichte) sind damit durch folgende Gleichung bestimmt:

$$(\mathbf{X} - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) = \sum_{i=1}^{p} \left( \frac{y_i}{\sqrt{\lambda_i}} \right)^2 = c$$

ightarrow Dies stellt in den y-Werten ein Ellipsoid mit den Hauptachsenlängen  $\sqrt{\lambda_i}$  dar!

#### Multivariate Normalverteilung

#### Eigenschaften:

- $ightharpoonup \mathbb{E}(\mathbf{X}) = oldsymbol{\mu}, \mathsf{Cov}(\mathbf{X}) = \Sigma$
- ▶ Für  $\mathbf{X} \sim \mathsf{N}_{p}(\ \mu\ ,\ \Sigma\ )$  und  $\mathbf{A} \in \mathbb{R}^{q \times p}, \mathbf{b} \in \mathbb{R}^{q}$  gilt

$$\mathbf{Y} = \mathbf{A} \, \mathbf{X} + \mathbf{b} \sim \mathsf{N}_{q} (\mathbf{A} \, \boldsymbol{\mu} + \mathbf{b} \; , \; \mathbf{A} \, \boldsymbol{\Sigma} \, \mathbf{A}^{ op}) \; .$$

 $\qquad \qquad \mathbf{(X} - \boldsymbol{\mu})^{\top} \boldsymbol{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi^2(\boldsymbol{p})$ 

#### Spezialfälle:

- Für p = 1 ergibt sich die univariate Normalverteilung mit Parametern  $\mu = \mathbb{E}(X)$  und  $\Sigma = \text{Var}(X)$ .
- ▶ Für  $\mathbf{X} \sim \mathsf{N}_p(\mathbf{0}, \mathbf{I})$ , also mit

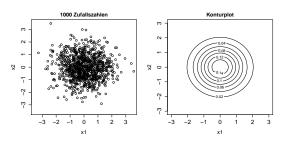
$$\mu = \mathbf{0} = egin{pmatrix} 0 \ dots \ 0 \end{pmatrix} \qquad \text{und} \qquad \Sigma = \mathbf{I} = egin{pmatrix} 1 & \cdots & 0 \ & \ddots & \ 0 & \cdots & 1 \end{pmatrix} \; ,$$

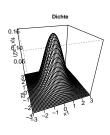
ergibt sich die multivariate Standardnormalverteilung.

Multivariate Verfahren – SS 21

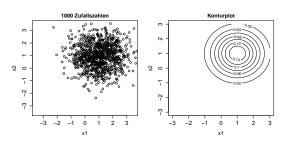
Verfeilungen – Fölle 44/59

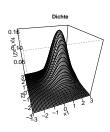
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \right)$$



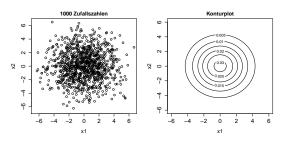


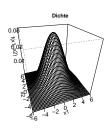
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \begin{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \end{pmatrix}$$



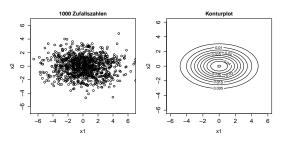


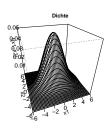
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 5 & 0 \\ 0 & 5 \end{pmatrix} \end{pmatrix}$$



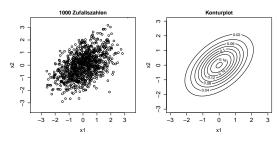


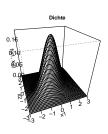
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 5 & 0 \\ 0 & 2 \end{pmatrix} \end{pmatrix}$$



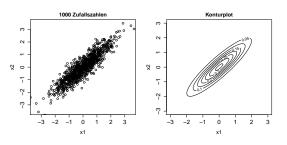


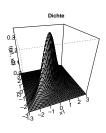
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix} \end{pmatrix}$$



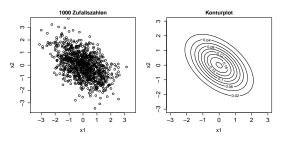


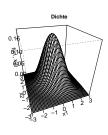
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & 0.9 \\ 0.9 & 1 \end{pmatrix} \end{pmatrix}$$



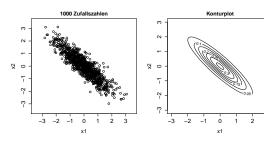


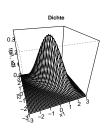
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & -0.5 \\ -0.5 & 1 \end{pmatrix} \right)$$



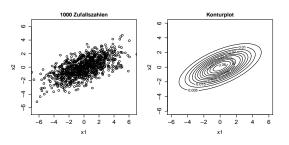


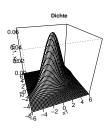
$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 & -0.9 \\ -0.9 & 1 \end{pmatrix} \right)$$





$$\begin{pmatrix} X_1 \\ X_2 \end{pmatrix} \sim N_2 \begin{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 5 & 2 \\ 2 & 2 \end{pmatrix} \end{pmatrix}$$





# Rand- und bedingte Verteilung

Sei  $X \sim N_p(\mu, \Sigma)$ . Betrachte die Partition

$$\mathbf{X} = egin{pmatrix} X_1 \ dots \ X_r \ X_{r+1} \ dots \ X_{
ho} \end{pmatrix} = egin{pmatrix} \mathbf{Y} \ \mathbf{Z} \end{pmatrix}$$

und damit

$$oldsymbol{\mu} = egin{pmatrix} \mu_1 \ dots \ \mu_r \ \mu_{r+1} \ dots \ \mu_{
ho} \end{pmatrix} = egin{pmatrix} \mu_Y \ \mu_Z \end{pmatrix} \qquad \Sigma = egin{pmatrix} \Sigma_Y & \Sigma_{YZ} \ \Sigma_{ZY} & \Sigma_Z \end{pmatrix}.$$

#### Rand- und bedingte Verteilung

#### Dann gilt:

Randverteilungen:

$$\mathbf{Y} \sim N_r(\mu_Y, \Sigma_Y)$$
  
 $\mathbf{Z} \sim N_q(\mu_Z, \Sigma_Z)$  mit  $q = p - r$ 

Bedingte Verteilung:

$$egin{align} \mathbf{Y}|\mathbf{Z} &= \mathbf{z}_0 \; \sim \; \mathsf{N}_r(\; \mu_{Y|Z} \,,\, \Sigma_{Y|Z} \,) \ \mathrm{mit} \quad \mu_{Y|Z} &= \mu_Y + \Sigma_{YZ} \cdot \Sigma_Z^{-1} (\mathbf{z}_0 - \mu_Z) \ \Sigma_{Y|Z} &= \Sigma_Y - \Sigma_{YZ} \, \Sigma_Z^{-1} \, \Sigma_{ZY} \ \end{split}$$

Unabhängigkeit:

 $\Sigma_{YZ} = 0 \Rightarrow \mathbf{Y}$  und  $\mathbf{Z}$  sind unabhängig also:  $\mathbf{Y}$  und  $\mathbf{Z}$  sind unabhängig  $\Leftrightarrow \Sigma_{YZ} = 0$ 

# Weitere multivariate Verteilungen

#### Wishart-Verteilung

Seien  $\mathbf{X}_1, \dots, \mathbf{X}_m \overset{i.i.d.}{\sim} N_p(\mathbf{0}, \Sigma)$ , dann ist die Matrix

$$\mathbf{M} = \sum_{i=1}^{m} \mathbf{X}_i \mathbf{X}_i^{\top} = \mathbf{X}^{\top} \mathbf{X} \in \mathbb{R}^{p \times p}$$

wishart-verteilt mit Parametern  $\Sigma$  und m.

- $\mathbf{M} \sim W_p(\Sigma, m)$
- ► Falls p = 1, so gilt  $\mathbf{M} = \sum_{i=1}^{m} X_i^2 \sim \sigma^2 \chi^2(m)$ , wobei die Komponenten  $X_i \sim N(0, \sigma^2)$
- ► Multivariate Erweiterung der χ²-Verteilung

# Hotellings $T^2$ -Verteilung

Seien  $\mathbf{d} \sim N_p(\mathbf{0}, \mathbf{I})$  und  $\mathbf{M} \sim W_p(\mathbf{I}, m)$  unabhängig, dann ist

$$u = m\mathbf{d}^{\mathsf{T}}\mathbf{M}^{-1}\mathbf{d}$$

Hotellings  $T^2$ -verteilt mit Parametern p und m.

- $u \sim T^2(p, m)$
- ▶ Falls p = 1, so ergibt sich die F(1, m)-Verteilung
- ▶ Seien  $\mathbf{d} \sim N_p(\mu, \Sigma)$  und  $\mathbf{M} \sim W_p(\Sigma, m)$  unabhängig, dann erhält man:

$$m(\mathbf{d} - \boldsymbol{\mu})^{\top} \mathbf{M}^{-1} (\mathbf{d} - \boldsymbol{\mu}) \sim T^2(p, m)$$

 Verwendung bei Testproblemen (multivariate Erweiterung der t-Verteilung bzw. des t-Tests)

#### Wilks' Λ-Verteilung

Seien  $\mathbf{A} \sim W_p(\mathbf{I}, m)$  und  $\mathbf{B} \sim W_p(\mathbf{I}, n)$  unabhängig, dann ist

$$\Lambda = \frac{\text{det}(\boldsymbol{\mathsf{A}})}{\text{det}(\boldsymbol{\mathsf{A}} + \boldsymbol{\mathsf{B}})}$$

Wilks'  $\Lambda$ -verteilt mit Parametern p, m und n.

- $ightharpoonup \Lambda \sim \Lambda(p, m, n)$
- ► Falls p = 1, so gilt  $A \sim \chi^2(m)$  und  $B \sim \chi^2(n)$  und damit erhält man:  $\Lambda \sim B(m/2, n/2)$
- Verwendung beim Testen im Rahmen der einfaktoriellen Varianzanalyse