#### 6. Tutorium Multivariate Verfahren

- Hauptkomponentenanalyse -

Andreas Hölzl:

23.06.2014 und 30.06.2014

Shuai Shao:

26.06.2014 und 03.07.2014

Institut für Statistik, LMU München

- Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenten
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

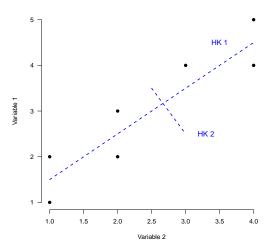
- Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenter
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

#### Problemstellung

- Instrument zur Erklärung der Variablität der Daten
- Ziel: einfache Interpretierbarkeit
- Vereinfachung und Veranschaulichung der Daten
- Reduktion der Daten auf wenige möglichst aussagekräftige Hauptkomponenten
  - ⇒ **Fragestellung:** Wie kann die Dimension mit möglichst geringem Informationsverlust reduziert werden?

Information ⇔ Varianz

#### Graphische Veranschaulichung



- 1 Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenten
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

#### 1. Hauptkomponente

- Ausgangsgrößen:
  - Zufallsvektor:  $\mathbf{x} = (x_1, \dots, x_p)^{\top}$
  - ullet Erwartungswertvektor:  $\mathbb{E}(\mathbf{x}) = oldsymbol{\mu}$
  - empirische Kovarianzmatrix:  $\Sigma = Cov(x)$
- Finde die Linear-Kombination  $y_1 = \mathbf{a}_1^{\top} \mathbf{x}$  mit Vektor  $\mathbf{a}_1 = (a_{11}, \ldots, a_{1p})^{\top}$ , sodass  $Var(y_1) = \mathbf{a}_1^{\top} \mathbf{\Sigma} \mathbf{a}_1$  maximal wird
- $y_1 = 1$ . Hauptkomponente
- Nebenbedingung:

$$\|{\pmb a}_1\|^2 = {\pmb a}_1^{ op} {\pmb a}_1 = 1$$

→ ansonsten ist das Problem nicht eindeutig lösbar!

#### 2. Hauptkomponente

- Finde im **zweiten** Schritt die Linear-Kombination  $y_2 = \mathbf{a}_2^{\top} \mathbf{x}$  mit Vektor  $\mathbf{a}_2 = (a_{21}, \ldots, a_{2p})^{\top}$ , sodass  $Var(y_2) = \mathbf{a}_2^{\top} \mathbf{\Sigma} \mathbf{a}_2$  maximal wird
- Nebenbedingungen:
  - $\|\mathbf{a}_2\|^2 = \mathbf{a}_2^{\top} \mathbf{a}_2 = 1$  (wie vorher)
  - $2 Cov(y_1, y_2) = 0 \Leftrightarrow \mathbf{a}_1 \perp \mathbf{a}_2$
- Merke: Die ersten beiden Hauptkomponenten sind unkorreliert und stehen somit aufeinander senkrecht!

- Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenten
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

# Maximierung unter Nebenbedinung (1. HK):

Lagrange:

$$egin{aligned} arphi(\mathbf{a}_1) &= \mathbf{a}_1^T \mathbf{\Sigma} \mathbf{a}_1 - \lambda (\mathbf{a}_1^T \mathbf{a}_1 - 1) \overset{\mathbf{a}_1}{ o} \max \ & \dfrac{\partial arphi}{d \mathbf{a}_1} = 2 \mathbf{\Sigma} \mathbf{a}_1 - 2 \lambda \mathbf{a}_1 \overset{!}{=} 0 \ & \Leftrightarrow \mathbf{\Sigma} \mathbf{a}_1 = \lambda \mathbf{a}_1 \quad \hat{=} \quad \text{Eigenwertproblem!} \end{aligned}$$

 $\Rightarrow$   $\mathbf{a}_1$  ist der Eigenvektor zum größten Eigenwert  $\lambda$  von  $\mathbf{\Sigma}$ 

## Maximierung unter Nebenbedinung (2. HK):

Lagrange:

$$\varphi(\mathbf{a}_2) = \mathbf{a}_2^T \mathbf{\Sigma} \mathbf{a}_2 - \underbrace{\lambda(\mathbf{a}_2^T \mathbf{a}_2 - 1)}_{1.\,\mathit{NB}} - \underbrace{\varphi(\mathbf{a}_1^\top \mathbf{a}_2)}_{2.\,\mathit{NB}} \overset{\mathbf{a}_2}{\to} \mathsf{max}$$

 $\Rightarrow$   $\mathbf{a}_2$  ist der Eigenvektor zum zweitgrößten Eigenwert  $\lambda$  von  $\Sigma$ 

Merke: Es können maximal p Hauptkomponenten bestimmt werden, was der Anzahl an betrachteten Variablen entspricht!

## Spektralzerlegung

 Man erhält den Vektor der Hauptkomponenten mittels Spektralzerlegung von Σ:

$$\mathbf{\Sigma} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^{\top}$$
 mit

$$\mathbf{P} = (\mathbf{p}_1, \dots, \mathbf{p}_p)$$
 Eigenvektoren von  $\mathbf{\Sigma}$  (entsprechen den gesuchten  $(\mathbf{a}_1, \dots, \mathbf{a}_p)$ )

$$oldsymbol{\Lambda} = egin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_p \end{pmatrix} \quad \text{Eigenwerte } \lambda_1 \geq \ldots \geq \lambda_p$$

• Kovarianz der Hauptkomponentenanalyse:

$$\mathsf{Cov}(\mathbf{y}) = \mathsf{Cov}(\mathbf{P}^{\top}\mathbf{x}) = \mathbf{P}^{\top}\mathbf{\Sigma}\mathbf{P} = \mathbf{\Lambda} = \begin{pmatrix} \lambda_1 & 0 \\ & \ddots & \\ 0 & & \lambda_p \end{pmatrix}$$

- Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenten
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

#### Geometrische Interpretation

Darstellung einer Beobachtung x im Koordinatensystem:

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_p \end{pmatrix} = x_1 \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + x_2 \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} + \dots + x_p \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 0 \\ 1 \end{pmatrix}$$

d.h.  $x_1, \ldots, x_p$  sind die Koordinaten von **x** zur **kanonischen** Basis

$$\mathbf{y} = \mathbf{P}^{\top} \mathbf{x} \Leftrightarrow \mathbf{x} = \mathbf{P} \mathbf{y}$$
 $\mathbf{x} = (\mathbf{p}_1 \dots \mathbf{p}_p) \begin{pmatrix} y_1 \\ \vdots \\ y_p \end{pmatrix} = y_1 \mathbf{p}_1 + \dots + y_p \mathbf{p}_p$ 

d.h.  $y_1, \ldots, y_p$  sind die Koordinaten von **x** zur Basis  $\mathbf{p}_1, \ldots, \mathbf{p}_p$ 

#### Bemerkungen

- Die Hauptkomponenten stellen neue Basisvektoren dar
- Die Hauptkomponenten haben die Richtung der Hauptachsen der zu Σ gehörigen Ellipsen
- Die Größe der Eigenwerte entspricht der Varianz der Hauptkomponenten und ist somit proportional zur Länge der Basisvektoren

#### Merke:

Bei Skalenänderung ändern sich die Eigenwerte und Eigenvektoren! ⇒ meist Verwendung **standardisierter** Daten bzw. der Korrelationsmatrix!

- Idee der Hauptkomponentenanalyse
- 2 Bestimmung der Hauptkomponenten
- 3 Lösung des Eigenwertproblems
- 4 Geometrische Interpretation
- 5 Anzahl nötiger Hauptkomponenten

#### Erklärte Varianz der Hauptkomponenten:

Gesamtvarianz:

$$\operatorname{tr}(\mathbf{\Sigma}) = \sum_{i=1}^{p} \operatorname{Var}(x_i)$$

Anteil erklärter Varianz durch r Hauptkomponenten

$$eV(r) = \frac{\sum_{i=1}^{r} Var(y_i)}{\sum_{i=1}^{p} Var(y_i)} = \frac{\sum_{i=1}^{r} \lambda_i}{\sum_{i=1}^{p} \lambda_i}$$

Der **Anteil der Varianz**, den die Hauptkomponenten erklären, ist ein ausschlaggebendes Kriterium für die **Anzahl** zu verwendender Hauptkomponenten!

#### Mögliche Kriterien

- Verwende soviele Hauptkomponenten bis ein gewisser Anteil x% der Gesamtvarianz der Daten erklärt ist
- ② Eine Hauptkomponente sollte mindestens genauso viel beitragen wie eine einzelne Variable im Durchschnitt. Im Fall normierter Variablen (Korrelationsmatrix) sind dies alle Hauptkomponenten mit Eigenwert  $\lambda>1$ .
- Betrachte eine graphische Darstellung der Eigenwerte (Scree-Plot). Verwende soviele Hauptkomponenten bis zum Knick des Graphen (Ellbogen).