Multivariate Verfahren

6. Diskriminanzanalyse

Moritz Berger

Institut für Statistik, LMU München

Sommersemester 2019

Ausgangssituation

Die Grundgesamtheit zerfällt in $g \geq 2$ disjunkte Klassen mit

Indikator $Y \in \{1, \dots, g\}$.

Man beobachtet Merkmalsvektoren $\mathbf{x}_1, \dots, \mathbf{x}_n$, die

Klassenzugehörigkeit Y_1, \ldots, Y_n ist jedoch *unbekannt*.

Problemstellung

Die Objekte a_1, \ldots, a_n sollen mithilfe der an ihnen beobachteten

Merkmalsvektoren in eindeutiger Weise jeweils genau einer Klasse zugeordnet werden.

Multivariate Verfahren 2/49

Beispiele

- Unterscheidung von Kreditnehmern (vertrauenswürdig / nicht vertrauenswürdig)
- Klassifizierung von Krankheiten (Bronchitis / Lungenentzündung)
- Bestimmung des Krankheitsstatus (krank / gesund)
- Identifizierung von Drogenkonsumenten (User / Non-User)
- Mustererkennung in Texten (Buchstaben)

Multivariate Verfahren 3/49

Merkmale der Diskriminanzanalyse

- Die Klassen, in die die Objekte eingeteilt werden sollen, sind vorab bekannt.
- Die Diskriminanzanalyse ist ein Verfahren des "supervised learning".
- Synonym verwendet werden auch die Begriffe "Klassifikation" und "Pattern Recognition".
- Die Grundlage der Diskriminanzanalyse sind Fehlerraten bzw.
 Fehlklassifikationswahrscheinlichkeiten.
- Die Auswahl der Merkmale, die für die Klassifikation herangezogen werden, sind von zentraler Bedeutung.

Multivariate Verfahren 4/49

Datengrundlage

Der Merkmalsvektor **x** und die Klasse *Y* sind charakterisiert durch:

a priori-Wahrscheinlichkeiten:

$$p(r) = P(Y = r), r = 1, ..., g$$

a posteriori-Wahrscheinlichkeiten:

$$P(r|\mathbf{x}) = P(Y = r|\mathbf{x}), r = 1, \dots, g$$

• die Dichte von x gegeben die Klasse:

$$f(\mathbf{x}|Y=1),\ldots,f(\mathbf{x}|Y=g)$$

• die Mischverteilung in der Gesamtpopulation:

$$f(\mathbf{x}) = \sum_{i=1}^{g} f(\mathbf{x}|j) p(j)$$

Multivariate Verfahren 5/49

Fehlklassifikationswahrscheinlichkeiten

Sei δ eine bestimmte, feste Zuordnungsregel und (\mathbf{x}, Y) ein Zufallsvektor.

Gesamt-Fehlerrate

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y), \quad \delta(\mathbf{x}) \in \{1, \dots, g\}$$

Fehlklassifikation, gegeben x

$$\varepsilon(\mathbf{x}) = P(\delta(\mathbf{x}) \neq Y|\mathbf{x})$$
$$= 1 - P(\delta(\mathbf{x}) = Y|\mathbf{x})$$

Multivariate Verfahren 6/49

Fehlklassifikationswahrscheinlichkeiten

Sei δ eine bestimmte, feste Zuordnungsregel und (\mathbf{x}, Y) ein Zufallsvektor.

Verwechslungswahrscheinlichkeit

$$\varepsilon_{rs} = P(\delta(\mathbf{x}) = s | Y = r) = \int_{\mathbf{x}: \delta(\mathbf{x}) = s} f(\mathbf{x} | r) dx$$

Fehlklassifikation, gegeben Klasse r

$$\varepsilon_r = P(\delta(\mathbf{x}) \neq r | Y = r) = \sum_{r \neq s} \varepsilon_{rs}$$

Multivariate Verfahren 7/49

Fehlklassifikationswahrscheinlichkeiten

Es gelten folgende Zusammenhänge:

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \sum_{r=1}^{g} P(\delta(\mathbf{x}) \neq r | Y = r) p(r)$$
$$= \sum_{r=1}^{g} \varepsilon_r p(r) = \sum_{r=1}^{g} \sum_{s \neq r} \varepsilon_{rs} p(r)$$

und

$$\varepsilon = P(\delta(\mathbf{x}) \neq Y) = \int P(\delta(\mathbf{x}) \neq Y | \mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$
$$= \int \varepsilon(\mathbf{x}) f(\mathbf{x}) d\mathbf{x}$$

Multivariate Verfahren 8/49

Bayes-Zuordnung

Ordne das Objekt mit Merkmalsvektor \mathbf{x} in diejenige Klasse zu, für welche die a posteriori-Wahrscheinlichkeit maximal ist, d.h.:

$$\delta(\mathbf{x}) = r \Leftrightarrow P(r|\mathbf{x}) = \max_{j} P(j|\mathbf{x}).$$

Wie erhält man die Zuordnung?

- $P(Y = r | \mathbf{x})$ bekannt \checkmark
- $f(\mathbf{x}|Y=r)$ bekannt \rightarrow Berechnung über den Satz von Bayes

$$P(r|\mathbf{x}) =$$

Multivariate Verfahren 9/49

Beispiel: Drogenkonsum

Multivariate Verfahren 10/49

Beispiel: Drogenkonsum - Fehlerraten

Multivariate Verfahren 11/49

Optimalität der Bayes-Zuordnung

Aus dem Zusammenhang auf Folie 8 kann man direkt sehen, dass die Gesamt-Fehlerrate ε minimal wird, falls $\varepsilon(\mathbf{x})$ für alle \mathbf{x} minimal ist.

Somit ergibt sich die beste Regel im Sinne einer kleinstmöglichen Gesamt-Fehlerrate durch minimieren von $\varepsilon(\mathbf{x}) = 1 - P\left(\delta(\mathbf{x})|\mathbf{x}\right)$.

 \Rightarrow Die Bayes-Zuordnung minmiert die Gesamtfehlerrate ε .

Multivariate Verfahren 12/49

Die Diskriminanzfunktion

Die Funktion $d_r(\mathbf{x}) = P(r|\mathbf{x})$ heißt Diskriminanzfunktion.

Damit lässt sich die Bayes-Zuordnungsregel wie folgt formulieren:

$$\delta(\mathbf{x}) = r \iff d_r(\mathbf{x}) = \max_j d_j(\mathbf{x})$$

Äquivalent dazu, sind die Diskriminanzfunktionen:

- $d_r(\mathbf{x}) = f(\mathbf{x}|r)p(r)$
- $d_r(\mathbf{x}) = \log(f(\mathbf{x}|r)) + \log(p(r))$

Multivariate Verfahren 13/49

Veranschaulichung der Bayes-Zuordnung

Betrachte zwei Klassen, wobei gilt: p(1) = p(2)

Multivariate Verfahren 14/49

Veranschaulichung der Bayes-Zuordnung

Betrachte zwei Klassen, wobei gilt: p(1) > p(2)

Multivariate Verfahren 15/49

Maximum-Likelihood-Zuordnung

Ordne das Objekt mit Merkmalsvektor **x** in diejenige Klasse zu, für welche die Dichte maximal ist, d.h.:

$$\delta_{\mathsf{ML}}(\mathbf{x}) = r \Leftrightarrow f(\mathbf{x}|r) = \max_{i} f(\mathbf{x}|j)$$

Die ML-Zuordnung entspricht der Bayes-Zuordnung ohne Berücksichtigung der a priori-Wahrscheinlichkeiten bzw. mit gleichen a priori-Wahrscheinlichkeiten $p(1) = \ldots = p(r) = \frac{1}{r}$.

Multivariate Verfahren 16/49

Betrachte die Kostenfunktion:

$$c(r,\hat{r})=c_{r\hat{r}}$$
.

Kosten der Zuordnung eines Objekts der Klasse r in die Klasse \hat{r} (\hat{r} Risiko oder Schaden).

Annahmen:

- $c_{r\hat{r}} \geq 0$
- $c_{rr}=0$

Multivariate Verfahren 17/49

Sei δ eine bestimmte, feste Zuordnungsregel und (\mathbf{x}, Y) eine neue Beobachtung, so ist $c_{Y,\delta(\mathbf{x})}$ eine Zufallsvariable.

Zur Bestimmung von δ betrachtet man den zu erwartenden Schaden $R:=\mathbb{E}(c_{Y,\delta(\mathbf{x})}).$

Bedingtes Risiko, gegeben x

$$r(\mathbf{x}) = \sum_{r=1}^{g} c_{r,\delta(\mathbf{x})} P(r|\mathbf{x}) = \mathbb{E}_{Y|\mathbf{x}}(c_{Y,\delta(\mathbf{x})})$$

Zu erwartender Schaden bei gegebenem x.

Multivariate Verfahren 18/49

Das Gesamt-Risiko ergibt sich zu

$$R = \mathbb{E}_{Y}(c_{Y,\delta(x)}) =$$

ightarrow Die Minimierung von $r(\mathbf{x})$ für jedes \mathbf{x} ergibt eine Minimierung des Gesamt-Risikos R

Multivariate Verfahren 19/49

Ordne das Objekt mit Merkmalsvektor **x** in diejenige Klasse zu, für welche der zu erwartende Schaden minimal ist, d.h.:

$$\delta_{K}(\mathbf{x}) = r \Leftrightarrow \sum_{k=1}^{g} c_{kr} P(k|\mathbf{x}) = \min_{j} \sum_{k=1}^{g} c_{kj} P(k|\mathbf{x})$$

Mit den Diskriminanzfunktionen

$$d_r(\mathbf{x}) = -\sum_{k=1}^g c_{kr} P(k|\mathbf{x}),$$

erhält man

$$\delta_K(\mathbf{x}) = r \Leftrightarrow d_r(\mathbf{x}) = \max_i d_j(\mathbf{x}).$$

Multivariate Verfahren 20/49

Spezialfälle

- $c_{r\hat{r}} = c, \ r \neq \hat{r},$
 - d.h. jede Verwechslung hat den selben Schaden.
 - \Rightarrow Bayes-Zuordnung
- $c_{r\hat{r}} = \frac{c}{p(r)},$
 - d.h. Schaden ist proportional zur Größe der Klassen.
 - ⇒ ML-Zuordnung

Multivariate Verfahren 21/49

Klassifikation unter Normalverteilung

Im Folgenden wird angenommen, dass $\mathbf{x}|r$ multivariat normalverteilt ist mit Dichte:

$$f(\mathbf{x}|\boldsymbol{\mu}_r, \boldsymbol{\Sigma}_r) = \frac{1}{(2\pi)^{p/2} \mid \boldsymbol{\Sigma}_r \mid^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_r)^{\top} \boldsymbol{\Sigma}_r^{-1} (\mathbf{x} - \boldsymbol{\mu}_r)\right\} \; .$$

Betrachte die Bayes-Zuordnungsregel *ohne* Kosten und die zugehörige Diskriminanzfunktion

$$d_r(\mathbf{x}) = \log(f(\mathbf{x}|r)) + \log(p(r))$$
=

Multivariate Verfahren 22/49

1. Spezialfall: $\mathbf{x}|r \sim N_p(\boldsymbol{\mu}_r, \sigma^2 \mathbf{I})$

Die Diskriminanzfunktion ergibt sich zu:

$$d_r(\mathbf{x}) = -rac{1}{2\sigma^2}(\mathbf{x} - \boldsymbol{\mu}_r)^{ op}(\mathbf{x} - \boldsymbol{\mu}_r) - rac{1}{2}\log(|\sigma^2\mathbf{I}|) + \log(p(r))$$
.

Für den Vergleich zweier Klassen r und \tilde{r} folgt damit:

$$d_r(\mathbf{x}) \geq d_{\tilde{r}}(\mathbf{x}) \Leftrightarrow$$

Multivariate Verfahren 23/49

1. Spezialfall: Skizze

Multivariate Verfahren 24/49

2. Spezialfall: $\mathbf{x}|r \sim N_p(\boldsymbol{\mu}_r, \boldsymbol{\Sigma})$

Die Diskriminanzfunktion ergibt sich zu:

$$\begin{aligned} d_r(\mathbf{x}) &= -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_r)^{\top} \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}_r) - \frac{1}{2} \log(|\boldsymbol{\Sigma}|) + \log(p(r)) \\ &= -\frac{1}{2} \mathbf{x}^{\top} \boldsymbol{\Sigma}^{-1} \mathbf{x} + \mathbf{x}^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_r - \frac{1}{2} \boldsymbol{\mu}_r^{\top} \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_r - \frac{1}{2} \log(|\boldsymbol{\Sigma}|) + \log(p(r)) \end{aligned}$$

Beachte: Alle Terme, die nicht von der Klasse r abhängen, sind für den Vergleich der Diskriminanzfunktionen irrelevant und können daher vernachlässigt werden. Damit gilt:

$$d_r(\mathbf{x}) =$$

Multivariate Verfahren 25/49

2. Spezialfall: Skizze

Multivariate Verfahren 26/49

Lineare vs. Quadratische Diskriminanzfunktion

Falls $\mathbf{x}|r \sim N_p(\mu_r, \mathbf{\Sigma})$ ergibt sich die Diskriminanzfunktion:

$$d_r(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_r - \frac{1}{2} \boldsymbol{\mu}_r^{\top} \mathbf{\Sigma}^{-1} \boldsymbol{\mu}_r + \log(p(r))$$
$$= \mathbf{a}_r^{\top} \mathbf{x} + a_{r0}$$

 \rightarrow Dies ist eine *lineare* Funktion in x.

Im 3. Fall, wenn $\mathbf{x}|r \sim N_p(\mu_r, \mathbf{\Sigma}_r)$, kann kein Term der log-Dichte vernachlässigt werden und die Diskriminanzfunktion hat die Gestalt:

$$d_r(\mathbf{x}) = \mathbf{x}^{\top} \mathbf{A}_r \mathbf{x} + \mathbf{a}_r^{\top} \mathbf{x} + a_{r0}$$

 \rightarrow Dies ist eine *quadratische* Funktion in **x**.

Multivariate Verfahren 27/49

3. Fall: Skizze

Multivariate Verfahren 28/49

Geschätzte Zuordnungregel

Bisher wurde davon ausgegangen, dass die wahre Verteilung zur Bestimmung der Zuordnung bekannt ist.

Sind Daten $\mathbf{x}_{(1)}^r,\ldots,\mathbf{x}_{(n_r)}^r,\ r=1,\ldots,g,$ gegeben (Lernstichprobe), so erhält man eine geschätzte Diskriminanzfunktion, indem man die Schätzer $\hat{\boldsymbol{\mu}}_r=\bar{\mathbf{x}}_r$ und $\hat{\boldsymbol{\Sigma}}_r=\mathbf{S}_r$ einsetzt.

Somit gilt für eine neue Beobachtung $\tilde{\mathbf{x}}$:

$$\hat{\delta}(\tilde{\mathbf{x}}) = r \iff d_r(\tilde{\mathbf{x}} \,|\, \bar{\mathbf{x}}_r, \mathbf{S}_r) = \max_j d_j(\tilde{\mathbf{x}} \,|\, \bar{\mathbf{x}}_j, \mathbf{S}_j)$$

Multivariate Verfahren 29/49

Eigenschaften

Für die Bayes-Zuordnung unter Normalverteilung gilt für den Gesamt-Fehler:

- $\varepsilon(\delta(quadratisch)) \le \varepsilon(\delta(linear))$
- $\varepsilon(\hat{\delta}) \geq \varepsilon(\delta)$

Betrachtet man den Erwartungswert $\mathbb{E}_L(\varepsilon(\hat{\delta}))$ über mehrere Lernstichproben, so gilt auch $\mathbb{E}_L(\varepsilon(\hat{\delta})) \geq \varepsilon(\delta)$, jedoch keine Dominanz der quadratischen Diskriminanzfunktion, d.h.:

$$\mathbb{E}_L(\varepsilon(\hat{\delta}(\mathsf{quadratisch}))) \nleq \mathbb{E}_L(\varepsilon(\hat{\delta}(\mathsf{linear})))$$

Multivariate Verfahren 30/49

Diskriminanzanalyse nach Fisher

(Zwei-Klassen-Fall)

Gegeben sind die Daten $\mathbf{x}_{(1)}^1, \dots, \mathbf{x}_{(n_1)}^1$ und $\mathbf{x}_{(1)}^2, \dots, \mathbf{x}_{(n_2)}^2$. Gesucht ist eine Projektion, d.h. eine Linearkombination

$$y = \mathbf{a}^{\mathsf{T}} \mathbf{x}, \quad \mathsf{mit} \quad \|\mathbf{a}\| = 1,$$

sodass die beiden Klassen bestmöglich getrennt werden.

Multivariate Verfahren 31/49

Graphische Veranschaulichung

Multivariate Verfahren 32/49

Kriterium von Fisher

Um eine maximale Trennung der beiden Klassen zu erzielen, wird folgendes Kriterium maximiert:

$$Q(\mathbf{a}) = \frac{(\bar{y}_1 - \bar{y}_2)^2}{w_1^2 + w_2^2},$$

wobei

$$\bar{y}_r = \frac{1}{n_r} \sum_{i=1}^{n_r} \mathbf{a}^\top \mathbf{x}_{(i)}^r = \mathbf{a}^\top \bar{\mathbf{x}}_r, \quad r = 1, 2,$$

$$w_r^2 = \sum_{i=1}^{n_r} (\mathbf{a}^\top \mathbf{x}_{(i)}^r - \mathbf{a}^\top \bar{\mathbf{x}}_r)^2, \quad r = 1, 2.$$

Multivariate Verfahren 33/49

Kriterium von Fisher

Es gilt:

$$w_1^2 + w_2^2 = \sum_{r=1}^2 \sum_{i=1}^{n_r} (\mathbf{a}^\top \mathbf{x}_{(i)}^r - \mathbf{a}^\top \bar{\mathbf{x}}_r)^2$$

$$= \mathbf{a}^\top \sum_{r=1}^2 \sum_{i=1}^{n_r} (\mathbf{x}_{(i)}^r - \bar{\mathbf{x}}_r) (\mathbf{x}_{(i)}^r - \bar{\mathbf{x}}_r)^\top \mathbf{a}$$

$$= \mathbf{a}^\top \mathbf{W} \mathbf{a}$$

Und damit:

$$Q(\mathbf{a}) = \frac{(\mathbf{a}^{\top}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2))^2}{\mathbf{a}^{\top}\mathbf{W}\,\mathbf{a}} \rightarrow \max_{\mathbf{a} \neq \mathbf{0}}$$

Multivariate Verfahren 34/49

Kriterium nach Fisher

Die Lösung ergibt sich durch Lösen der Gleichung: $\frac{\partial Q(\mathbf{a})}{\partial \mathbf{a}} = 0$.

Also:

$$\frac{\partial Q(\mathsf{a})}{\partial \mathsf{a}} =$$

Multivariate Verfahren 35/49

Vergleich zur linearen Diskriminanzanalyse

Unter Normalverteilungsannahme mit gleichen Kovarianzmatrizen gilt für den Vergleich zweier Diskriminanzfunktionen

$$d_1(\mathbf{x}) = d_2(\mathbf{x})$$

 $\Leftrightarrow \mathbf{a}_1^{\top} \mathbf{x} + a_{10} = \mathbf{a}_2^{\top} \mathbf{x} + a_{20}$
 $\Leftrightarrow (\mathbf{a}_1 - \mathbf{a}_2)^{\top} \mathbf{x} = a_{20} - a_{10}$

Da $(\mathbf{a}_1 - \mathbf{a}_2) = \mathbf{S}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$ gilt, ergibt sich in diesem Fall das Kriterium nach Fisher.

Multivariate Verfahren 36/49

Diskriminanzanalyse nach Fisher

(Mehr-Klassen-Fall)

Gegeben sind die Daten $\mathbf{x}_{(1)}^r, \dots, \mathbf{x}_{(n_r)}^r, r = 1, \dots, g$.

Gesucht ist eine Projektion $y = \mathbf{a}^{\top} \mathbf{x}$, welche durch Maximierung von

$$Q(\mathbf{a}) = \frac{\sum_{r=1}^{g} n_r (\bar{y}_r - \bar{y})^2}{\sum_{r=1}^{g} w_r^2}$$

bestimmt ist, wobei

$$\bar{y} = \frac{1}{n} \sum_{r=1}^{g} n_r \bar{y}_r .$$

Multivariate Verfahren 37/49

Kriterium nach Fisher

Der Zähler von $Q(\mathbf{a})$ ergibt:

$$\sum_{r=1}^{g} n_r (\bar{y}_r - \bar{y})^2 = \sum_{r=1}^{g} n_r (\mathbf{a}^\top \bar{\mathbf{x}}_r - \mathbf{a}^\top \bar{\mathbf{x}})^2$$
$$= \mathbf{a}^\top \sum_{r=1}^{g} n_r (\bar{\mathbf{x}}_r - \bar{\mathbf{x}}) (\bar{\mathbf{x}}_r - \bar{\mathbf{x}})^\top \mathbf{a} = \mathbf{a}^\top \mathbf{B} \mathbf{a}$$

Und damit (mit dem Resultat auf Folie 34):

$$Q(\mathbf{a}) = rac{\mathbf{a}^{ op} \mathbf{B} \, \mathbf{a}}{\mathbf{a}^{ op} \mathbf{W} \, \mathbf{a}} \,
ightarrow \, \max_{\mathbf{a}
eq \mathbf{0}}$$

Multivariate Verfahren 38/49

Kriterium nach Fisher

Die Lösung ergibt sich durch Lösen der Gleichung: $\frac{\partial \textit{Q}(a)}{\partial a} = 0.$

Also:

$$\frac{\partial Q(\mathbf{a})}{\partial \mathbf{a}} =$$

⇒ Es ergibt sich ein verallgemeinertes Eigenwertproblem!

Multivariate Verfahren 39/49

Lösung des Eigenwertproblems

Das verallgemeinerte Eigenwertproblem hat generell die Form

$$\mathbf{W}^{-1}\mathbf{B}\mathbf{a} = \lambda \mathbf{a}$$

wobei W und B symmetrisch sind und W außerdem positiv definit.

Möglicher Lösungsansatz:

Zerlege \mathbf{W} mittels Cholesky-Zerlegung: $\mathbf{W} = \mathbf{L}\mathbf{L}^{\top}$. Die Eigenwerte der Matrix $\mathbf{H} := \mathbf{L}^{-1}\mathbf{B}(\mathbf{L}^{-1})^{\top}$ sind dann identisch zu den Eigenwerten von $\mathbf{W}^{-1}\mathbf{B}$.

Multivariate Verfahren 40/49

Lösung des Eigenwertproblems

Da $\operatorname{rg}(\mathbf{W})=p$ und $\operatorname{rg}(\mathbf{B})=q\leq \min\{p,g-1\}$ ist, besitzt $\mathbf{W}^{-1}\mathbf{B}$ höchstens q Eigenwerte $\lambda_1,\ldots,\lambda_q$ mit zugehörigen Eigenvektoren $\mathbf{a}_1,\ldots,\mathbf{a}_q$.

Man erhält die Lösungen:

$$\lambda_r = \frac{\mathbf{a}_r^{\top} \mathbf{B} \, \mathbf{a}_r}{\mathbf{a}_r^{\top} \mathbf{W} \, \mathbf{a}_r}, \quad r = 1, \dots, q,$$

und die "kanonischen Variablen"

$$y_r = \mathbf{a}_r^{\top} \mathbf{x}, \quad r = 1, \dots, q.$$

Multivariate Verfahren 41/49

Graphische Veranschaulichung

Multivariate Verfahren 42/49

Praktisches Vorgehen

Ordne die Eigenwerte $\lambda_1, \ldots, \lambda_q$ der Größe nach und verwende alle oder nur $m \leq q$ Komponenenten (Projektionsrichtungen).

Betrachte die Entscheidungsregel:

$$\delta(\mathbf{x}) = r \Leftrightarrow \sum_{r=1}^{m} (\mathbf{a}_r \mathbf{x} - \mathbf{a}_r^{\top} \bar{\mathbf{x}}_r)^2 = \min_{j} \sum_{r=1}^{m} (\mathbf{a}_r \mathbf{x} - \mathbf{a}_r^{\top} \bar{\mathbf{x}}_j)^2$$

Beachte: Es kann (wieder) gezeigt werden, dass dieses Kriterium äquivalent ist zur ML-Zuordnung unter Normalverteilungsannahme mit gleichen Kovarianzmatrizen.

Multivariate Verfahren 43/49

Klassifikation anhand der k-nächsten Nachbarn

Betrachte die Gesamtstichprobe (\mathbf{x}_i, Y_i) , i = 1, ..., n.

Bestimme zu jedem Merkmalsvektor \mathbf{x}_i diejenigen

Merkmalsvektoren, die *am nähesten* an \mathbf{x}_i liegen. Berechne dafür die Distanzen

$$d(\mathbf{x}_i,\mathbf{x}_s), \quad i\neq s,$$

über ein geeignetes Distanzmaß d, z.B. die quadrierte, euklidische Distanz.

Multivariate Verfahren 44/49

Klassifikation anhand der k-nächsten Nachbarn

Bestimme zu \mathbf{x}_i die k nächsten Nachbarn, bezeichnet durch $\mathbf{x}_{(1)}, \dots, \mathbf{x}_{(k)}$ mit

$$d(\mathbf{x}_i, \mathbf{x}_{(1)}) \leq d(\mathbf{x}_i, \mathbf{x}_{(2)}) \leq \ldots \leq d(\mathbf{x}_i, \mathbf{x}_{(k)}).$$

Bezeichnet $Y_{(1)}, \ldots, Y_{(k)}$ die Klasse zu $\mathbf{x}_{(1)}, \ldots, \mathbf{x}_{(k)}$, so ergibt sich die Zuordnungsregel:

$$\delta(\mathbf{x}_i) = r \Leftrightarrow r$$
 ist die häufigste Klasse in $\{Y_{(1)}, \dots, Y_{(k)}\}$

Multivariate Verfahren 45/49

k-nächsten Nachbarn: Eigenschaften

- Die k-nächste Nachbarn Klassifikation ist ein verteilungsfreies bzw. nichtparametrisches Verfahren, d.h. es gibt keine Annahme an die Verteilung von x|r.
- Stellschrauben des Verfahrens sind die Distanz d und die Anzahl der nächsten Nachbarn k.

Multivariate Verfahren 46/49

Logistische Regression (Zwei-Klassen-Fall)

Ausgehend von den Zufallsvektoren (x, Y) postuliert man für die a posteriori-Wahrscheinlichkeiten:

$$P(Y = 1|\mathbf{x}) = \frac{\exp(\beta_0 + \mathbf{x}^{\top}\boldsymbol{\beta})}{1 + \exp(\beta_0 + \mathbf{x}^{\top}\boldsymbol{\beta})}$$
 und

$$P(Y = 2|\mathbf{x}) = \frac{1}{1 + \exp(\beta_0 + \mathbf{x}^{\top}\boldsymbol{\beta})}$$

Aquivalent kann postuliert werden:

$$\log\left(\frac{f(\mathbf{x}|1)}{f(\mathbf{x}|2)}\right) = \tilde{\beta}_0 + \mathbf{x}^{\top}\boldsymbol{\beta}, \quad \text{wobei} \quad \beta_0 = \tilde{\beta}_0 + \log\left(\frac{p(1)}{p(2)}\right)$$

Multivariate Verfahren 47/49

Logistische Regression: Zuordnungsregeln

Ordne das Objekt mit Merkmalsvektor **x** gemäß

Bayes-Zuordnungsregel in Klasse 1 zu, falls

$$d(\mathbf{x}) = \beta_0 + \mathbf{x}^{\top} \boldsymbol{\beta} \ge 0,$$

ansonsten zu Klasse 2.

Wird β_0 durch $\tilde{\beta}_0$ ersetzt erhält man eine Zuordnung gemäß ML-Zuordnungsregel.

Multivariate Verfahren 48/49

Logistische Regression: Eigenschaften

- Es wird keine Annahme an die Verteilung von $\mathbf{x}|r$ gemacht.
- Einfache Verallgemeinerung für g Klassen ist möglich.
- Der Ansatz der (linearen) logistischen Regression ist für eine Reihe von Klassendichten erfüllt, z.B. für die Multinomialverteilung mit gleichen Kovarianzmatrizen.
- Die Parameter β_0 und β sind in der Regel unbekannt und müssen geschätzt werden (analog zur Beschreibung auf Folie 29).

Multivariate Verfahren 49/49