Multivariate Verfahren

2. Multivariate Verteilungen

Moritz Berger

Institut für Statistik, LMU München

Sommersemester 2019

Multivariate Zufallsvariablen

Wir betrachten Zufallsvektoren

$$\mathbf{X} = egin{pmatrix} X_1 \ dots \ X_p \end{pmatrix} \in \mathbb{R}^p \, ,$$

mit Erwartungswertvektor

$$\mathbb{E}(\mathbf{X}) = oldsymbol{\mu} = \mathbb{E} egin{pmatrix} X_1 \ dots \ X_{
ho} \end{pmatrix} = egin{pmatrix} \mathbb{E}(X_1) \ dots \ \mathbb{E}(X_{
ho}) \end{pmatrix},$$

bzw. Erwartungswertmatrix

$$\mathbb{E}(\mathbf{X}) = (\mathbb{E}(X_{ij}))$$
.

Multivariate Verfahren 2/18

Multivariate Zufallsvariablen

Die Zusammenhangsstruktur in X wird durch die Kovarianz

$$cov(\mathbf{X}) = \mathbf{\Sigma} = (\sigma_{ij})$$

erfasst, wobei

$$\sigma_{ij} = cov(X_i, X_j) = \mathbb{E}(X_i - \mathbb{E}(X_i))\mathbb{E}(X_j - \mathbb{E}(X_j)),$$

$$\sigma_{ii} = cov(X_i, X_i) = var(X_i) = \sigma_i^2.$$

Multivariate Verfahren 3/18

Multivariate Zufallsvariablen

Für zwei Vektoren $\mathbf{X} = (X_1, \dots, X_p)^{ op}$ und $\mathbf{Y} = (Y_1, \dots, Y_q)$ gilt

$$\mathbf{\Sigma}_{XY} = cov(\mathbf{X}, \mathbf{Y}) = \begin{pmatrix} cov(X_1, Y_1) & \dots & cov(X_1, Y_q) \\ \vdots & \vdots & \vdots \\ cov(X_p, Y_1) & \dots & cov(X_p, Y_q) \end{pmatrix}$$

 $\rightarrow \Sigma_{XY}$ ist i.A. nicht symmetrisch!

Multivariate Verfahren 4/18

Rechenregeln

Beachte: A, B, a und b sind konstant.

Multivariate Verfahren 5/18

Zerlegung der Kovarianzmatrix

Es gilt:

$$\mathbf{\Sigma} = \mathbf{\Sigma}^{\frac{1}{2}} \mathbf{\Sigma}^{\frac{1}{2}}$$
 bzw. $\mathbf{\Sigma} = \mathbf{\Sigma}^{\frac{1}{2}} \mathbf{\Sigma}^{\frac{T}{2}}$

und

$$\mathbf{\Sigma}^{-1} = \mathbf{\Sigma}^{-\frac{T}{2}} \mathbf{\Sigma}^{-\frac{1}{2}}$$

Daraus resultiert:

$$cov(\mathbf{\Sigma}^{-\frac{1}{2}}\mathbf{X}) =$$

 $\Rightarrow \mathbf{\Sigma}^{-\frac{1}{2}}(\mathbf{X} - \mathbb{E}(\mathbf{X}))$ hat Erwartungswert $\mathbf{0}$ and Varianz \mathbf{I} .

Multivariate Verfahren 6/18

Spektralzerlegung

Es gilt:

$$\mathbf{\Sigma} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^{\top}$$
 und $\mathbf{\Sigma}^{-1} = \mathbf{P} \mathbf{\Lambda}^{-1} \mathbf{P}^{\top}$,

wobei

 $\mathbf{P} = (\mathbf{p}_1, \dots, \mathbf{p}_p)^{\top}$: Matrix der *orthonormalen* Eigenvektoren und

 $oldsymbol{\Lambda} = diag(\lambda_1, \dots, \lambda_p)$: Diagonalmatrix der geordneten Eigenwerte.

Multivariate Verfahren 7/18

Stetige Zufallsvektoren

Ein Zufallsvektor X heißt stetig verteilt, falls eine Dichte

$$f(\mathbf{X}) = f(X_1, \ldots, X_p) \geq 0$$

existiert mit Verteilungsfunktion

$$F(\mathbf{X}) = F(X_1, \ldots, X_p) = \int_{-\infty}^{X_p} \ldots \int_{-\infty}^{X_1} f(u_1, \ldots, u_p) du_1, \ldots, du_p,$$

wobei $0 \le F(\mathbf{X}) \le 1$.

Multivariate Verfahren 8/18

Multivariate Normalverteilung

Der Zufallsvektor $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ heißt multivariat normalverteilt mit Dichtefunktion

$$f(\mathbf{X}) = rac{1}{(2\pi)^{p/2} \mid \mathbf{\Sigma} \mid^{1/2}} \exp \left\{ -rac{1}{2} (\mathbf{X} - \boldsymbol{\mu})^{ op} \mathbf{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu})
ight\} \,.$$

- $\mu \in \mathbb{R}^p$: Erwartungswert
- $\Sigma \in \mathbb{R}^{p \times p}$: Kovarianzmatrix
- ightarrow Die Kovarianzmatrix $oldsymbol{\Sigma}$ ist symmetrisch und positiv definit. Damit exisitiert auch $oldsymbol{\Sigma}^{-1}$.

Multivariate Verfahren 9/18

Zusammenhang zur Spektralzerlegung

Es gilt:

$$\begin{split} (\mathbf{X} - \boldsymbol{\mu})^{\top} \mathbf{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) = & (\mathbf{X} - \boldsymbol{\mu})^{\top} \mathbf{P} \mathbf{\Lambda}^{-1} \mathbf{P}^{\top} (\mathbf{X} - \boldsymbol{\mu}) = \\ = & \mathbf{Y} \mathbf{\Lambda}^{-1} \mathbf{Y}^{\top} = \sum_{i=1}^{p} \frac{y_i^2}{\lambda_i} = \sum_{i=1}^{p} \left(\frac{y_i}{\sqrt{\lambda_i}} \right)^2 \end{split}$$

Die Isodensiten sind damit durch folgende Gleichung bestimmt:

$$(\mathbf{X} - \boldsymbol{\mu})^{\top} \mathbf{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) = \sum_{i=1}^{p} \left(\frac{y_i}{\sqrt{\lambda_i}} \right)^2 = c$$

ightarrow Dies stellt in den y-Werten ein Ellipsoid mit den Hauptachsenlängen $\sqrt{\lambda}_i$ dar!

Multivariate Verfahren 10/18

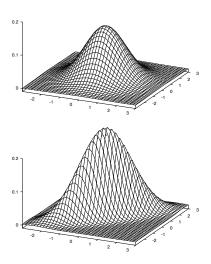
Bivariate Normalverteilung

$$f(X_1, X_2) =$$

mit

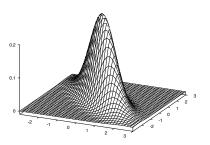
$$\Sigma =$$

Beispiele



Multivariate Verfahren 12/18

Beispiele



Multivariate Verfahren 13/18

Eigenschaften

$$\textbf{ AX} + \textbf{b} \sim \textit{N}\left(\textbf{A}\boldsymbol{\mu} + \textbf{b}, \textbf{A}\boldsymbol{\Sigma}\textbf{A}^{\top}\right)$$
 Insbesondere gilt: $\textit{X}_i \sim \textit{N}(\mu_i, \sigma_i^2)$, denn

2
$$\Sigma^{-1}(X - \mu) \sim N_p(0, I)$$

3
$$(\mathbf{X} - \boldsymbol{\mu})^{\top} \mathbf{\Sigma}^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi^{2}(p)$$

Multivariate Verfahren 14/18

Bedingte Normalverteilung

Sei

$$\mathbf{Z} = \begin{pmatrix} \mathbf{Y} \\ \mathbf{X} \end{pmatrix} \sim \mathit{N} \left(\boldsymbol{\mu}_{\mathit{Z}} = \begin{pmatrix} \boldsymbol{\mu}_{\mathit{Y}} \\ \boldsymbol{\mu}_{\mathit{X}} \end{pmatrix}, \boldsymbol{\Sigma}_{\mathit{Z}} = \begin{pmatrix} \boldsymbol{\Sigma}_{\mathit{YY}} & \boldsymbol{\Sigma}_{\mathit{YX}} \\ \boldsymbol{\Sigma}_{\mathit{XY}} & \boldsymbol{\Sigma}_{\mathit{XX}} \end{pmatrix} \right) \,,$$

dann gilt für die bedingte Verteilung

$$\mathbf{Y}|\mathbf{X} \sim \mathcal{N}\left(oldsymbol{\mu}_{Y|X}, \mathbf{\Sigma}_{Y|X}
ight)\,,$$

mit

$$egin{aligned} & \mu_{Y|X} = & \mu_{Y} + \mathbf{\Sigma}_{YX} \mathbf{\Sigma}_{XX}^{-1} (\mathbf{X} - \mu_{X}) \,, \\ & \mathbf{\Sigma}_{Y|X} = & \mathbf{\Sigma}_{YY} - \mathbf{\Sigma}_{YX} \mathbf{\Sigma}_{XX}^{-1} \mathbf{\Sigma}_{XY} \,. \end{aligned}$$

Multivariate Verfahren 15/18

Wishart-Verteilung

Seien $\mathbf{X}_1, \dots, \mathbf{X}_m \overset{i.i.d.}{\sim} N_p(\mathbf{0}, \mathbf{\Sigma})$, dann ist die Matrix

$$\mathbf{M} = \sum_{i=1}^{m} \mathbf{X}_{i} \mathbf{X}_{i}^{\top} = \mathbf{X}^{\top} \mathbf{X} \in \mathbb{R}^{p \times p}$$

wishart-verteilt mit Parametern Σ und m.

- $\mathbf{M} \sim W_p(\mathbf{\Sigma}, m)$
- Falls p=1, so gilt $\mathbf{M}=\sum_{i=1}^m X_i^2 \sim \chi^2(m)$, wobei die Komponenten $X_i \sim \mathcal{N}(0,\sigma^2)$

Multivariate Verfahren 16/18

Hotellings T²-Verteilung

Seien $\mathbf{d} \sim N_p(\mathbf{0},\mathbf{I})$ und $\mathbf{M} \sim W_p(\mathbf{I},m)$ unabhängig, dann ist

$$u = m\mathbf{d}^{\mathsf{T}}\mathbf{M}^{-1}\mathbf{d}$$

Hottelings T^2 -verteilt mit Parametern p und m.

- $u \sim T^2(p, m)$
- Falls p = 1, so ergibt sich die F(1, m)-Verteilung
- Seien $\mathbf{X} \sim N_p(\mu, \mathbf{\Sigma})$ und $\mathbf{M} \sim W_p(\mathbf{\Sigma}, m)$, dann erhält man:

Multivariate Verfahren 17/18

Wilks' ∧-Verteilung

Seien $\mathbf{A} \sim W_p(\mathbf{I},m)$ und $\mathbf{B} \sim W_p(\mathbf{I},n)$ unabhängig, dann ist

$$\Lambda = \frac{\det(\mathbf{A})}{\det(\mathbf{A} + \mathbf{B})}$$

Wilks' Λ -verteilt mit Parametern p, m und n.

- $\Lambda \sim \Lambda(p, m, n)$
- Falls p=1, so gilt $A \sim \chi^2(m)$ und $B \sim \chi^2(n)$ und damit erhält man: $\Lambda \sim B(m/2, n/2)$

Multivariate Verfahren 18/18